

FACULTE DES SCIENCES BEN M'SICK
UNIVERSITÉ HASSAN II DE CASABLANCA

PROJET DE FIN DE MODULE

BIO-INFORMATIQUE

Master Excellence en Intelligence Artificielle

Sous le thème :

Prédiction de l'efficacité de médicaments anticancéreux avec Machine Learning

Réalisé par :

Hajar ELKHALIDI

Imrane TAYA

Hamza RBIB

Hajar BENTAIB

Encadré par :

Dr. Ichrak BENAMRI

Année universitaire 2025–2026

Table des matières

Résumé **5**

Abstract **6**

1 Introduction générale **7**
1.1 Contexte du projet 7
1.2 Organisme d'accueil 7
1.3 Problématique et besoins 8
1.4 Objectifs 8
1.5 Résultats attendus et impact 8
1.6 Structure du rapport 9

2 Cahier de charges et déroulement du projet **10**
2.1 Cahier de charges 10
2.1.1 Problématiques et Besoins 10
2.1.2 Objectifs 11
2.2 Déroulement du projet 11
2.2.1 GANTT 11
2.2.2 Distribution de rôles 12
2.2.3 Méthodologie de gestion 12

3 Étude bibliographique **14**
3.1 Définitions des standards et des concepts de base 14
3.1.1 Lignées cellulaires cancéreuses 14
3.1.2 Médicaments anticancéreux 14
3.1.3 Mesures de réponse aux traitements 14
3.2 Documentation nécessaire : Modèles IA, statistiques et enquêtes existantes . . . 15
3.2.1 Source des données 15
3.2.2 Structure des données 15
3.2.3 Prétraitement et nettoyage des données 15
3.2.4 Sélection des variables et préparation pour le Machine Learning 16
3.2.5 Normalisation et encodage 16
3.2.6 Analyse exploratoire et visualisations 16
3.2.7 Ressources et reproductibilité 21
3.3 Autres projets similaires ou en relation à l'objectif 21

3.3.1 Évaluation critique des prédicteurs précliniques 21
3.3.2 Régression multi-cible et Support Vector Regression 21
3.3.3 Apprentissage à partir de voies moléculaires dérivées du génome 22
3.3.4 Positionnement de notre projet 22

4 Vue générale **23**
4.1 Architecture du système 23
4.2 Composants du système 24
4.3 Diagrammes UML 24
4.4 Choix des modèles AI et justification des choix 27
4.5 Choix des datasets d'entraînements 27
4.6 Architecture réseau 28
4.7 Modèles BI 28

5 Implémentation et résultats **29**
5.1 Environnement software et hardware 29
5.2 Résultats 29
5.3 Interprétation des résultats 30
5.4 Discussion et critiques 31

6 Conclusion générale et perspectives **33**
6.1 Bref rappel des objectifs 33
6.2 Vue globale sur les résultats obtenus 33
6.3 Impact du projet dans le contexte étudié 34
6.4 Impact sur votre formation et carrière 34
6.5 Perspectives 34

Table des figures

3.1 Distribution de LN_IC50 (histogramme et densité). 17
3.2 Distribution de AUC (histogramme et densité). 17
3.3 Distribution de LN_IC50 selon le type de cancer (CANCER_TYPE). 18
3.4 Distribution de LN_IC50 selon le tissu d'origine (GDSC_TISSUE_1). 18
3.5 Relation entre AUC et LN_IC50 (nuage de points). 20
3.6 Matrice de corrélation des variables numériques (heatmap). 20

4.1 Diagramme d'activité (vue pipeline). 25
4.2 Diagramme de composants (vue logique). 26

Liste des tableaux

2.1 Diagramme de GANTT du projet 12
2.2 Distribution des rôles au sein de l'équipe 12

Résumé

Le cancer demeure une cause majeure de mortalité et, au-delà du choix des protocoles thérapeutiques, la prédiction de l'efficacité d'un médicament reste difficile en raison de la forte variabilité de réponse entre tumeurs. Dans une perspective de médecine de précision, l'objectif de ce projet est de construire un modèle prédictif de la sensibilité aux médicaments anticancéreux à partir de données précliniques de lignées cellulaires.

Le travail s'appuie sur les ressources *Genomics of Drug Sensitivity in Cancer* (GDSC), et plus précisément sur GDSC2, qui fournit des courbes dose–réponse et des indicateurs quantitatifs de réponse aux traitements [1]. Dans le notebook, nous intégrons trois sources : (i) les mesures de réponse aux médicaments (notamment **LN_IC50** comme variable cible et **AUC** pour l'analyse exploratoire), (ii) les métadonnées des lignées cellulaires (ex. type tumoral, tissus, statut MSI, propriétés de croissance), et (iii) les annotations des composés (ex. cibles et voies associées). Les tables sont nettoyées puis fusionnées de manière robuste via **COSMIC_ID** (lignée) et **DRUG_ID** (médicament), avec une attention particulière portée à la gestion des doublons et des valeurs manquantes. Une ingénierie de variables légère est ensuite appliquée, par exemple en dérivant des indicateurs à partir des champs de cibles (nombre de cibles, présence de multi-ciblage, premières cibles) et en ajoutant des interactions catégorielles (ex. tissu $\times$ voie).

Pour l'apprentissage, plusieurs modèles de régression sont comparés (Ridge, ElasticNet, RandomForest, ExtraTrees, HistGradientBoosting). L'évaluation est réalisée par **validation croisée GroupKFold** en groupant sur **COSMIC_ID** afin de limiter la fuite d'information entre plis (une même lignée ne doit pas apparaître simultanément dans l'entraînement et le test). Les performances sont rapportées via RMSE, MAE et R^2, et des *baselines* (prédiction par moyenne conditionnelle, notamment par médicament) sont ajoutées pour détecter des scores artificiellement optimistes. Cette démarche s'inscrit dans la continuité des travaux utilisant l'apprentissage automatique pour anticiper l'efficacité anticancéreuse ou guider la priorisation de candidats [3, 4], tout en rappelant que la seule « puissance » in vitro ne suffit pas à garantir l'efficacité clinique [2].

Enfin, ce projet illustre une chaîne de traitement reproductible allant du nettoyage/alignement des données à l'évaluation rigoureuse des modèles. Les résultats obtenus restent toutefois limités au cadre préclinique des lignées cellulaires et aux annotations disponibles dans les fichiers exploités ; ils constituent une base méthodologique avant une extension vers des variables omiques plus riches et/ou une validation sur des données indépendantes. Pour la contextualisation biologique (gènes, cibles, voies), des ressources de référence comme NCBI peuvent être mobilisées [5].

Abstract

Predicting anticancer drug efficacy is challenging due to heterogeneous responses across tumor models. This project investigates a machine learning pipeline for drug sensitivity prediction using preclinical cancer cell line data, with the goal of estimating **LN_IC50** for a given (cell line, drug) pair.

We rely on the *Genomics of Drug Sensitivity in Cancer* resource, focusing on GDSC2 dose–response data [1]. In the corrected notebook, three data sources are integrated : (i) drug response measurements (with **LN_IC50** as the target and **AUC** used for exploratory consistency checks), (ii) cell line metadata (e.g., tissue descriptors, cancer type, MSI status, growth properties), and (iii) compound annotations (e.g., targets and pathways). After robust cleaning and merging on **COSMIC_ID** and **DRUG_ID**, light feature engineering is performed, including target-derived indicators (e.g., number of targets, multi-target flag) and categorical interaction terms.

Several regression models are benchmarked (Ridge, ElasticNet, RandomForest, ExtraTrees, HistGradientBoosting). Model performance is assessed using **GroupKFold cross-validation grouped by COSMIC_ID** to reduce information leakage across folds. Metrics include RMSE, MAE, and R^2, and mean-based baselines (especially per-drug averages) are reported to detect inflated results. This workflow aligns with recent efforts that leverage machine learning for anticancer efficacy prediction and drug repurposing [3, 4], while acknowledging broader limitations of relying solely on in vitro potency as a proxy for real-world efficacy [2]. Biological interpretation of targets and gene-related concepts can be supported by reference resources such as NCBI [5].

Overall, the project provides a reproducible end-to-end methodology—from data integration to leakage-aware evaluation—for anticancer drug response prediction in a preclinical setting, and serves as a foundation for future extensions toward richer omics features and external validation.

Chapitre 1

Introduction générale

1.1 Contexte du projet

Le cancer représente aujourd'hui l'un des principaux enjeux de santé publique à l'échelle mondiale, en raison de sa forte incidence et de sa complexité biologique. Malgré les avancées significatives réalisées dans le développement des thérapies anticancéreuses, la réponse aux traitements varie considérablement d'un patient à un autre. Cette variabilité s'explique en grande partie par l'hétérogénéité moléculaire des tumeurs, rendant inefficace l'approche thérapeutique uniforme traditionnellement adoptée en oncologie.

Avec l'essor des technologies de séquençage à haut débit et la disponibilité massive de données biologiques, la bioinformatique s'est imposée comme un levier essentiel pour l'analyse et l'interprétation des données génomiques. Parallèlement, les progrès de l'intelligence artificielle et de l'apprentissage automatique offrent de nouvelles perspectives pour modéliser des relations complexes entre les caractéristiques moléculaires des cancers et leur réponse aux médicaments. Ces approches ouvrent la voie à la médecine de précision, dont l'objectif est d'adapter les traitements en fonction du profil biologique spécifique de chaque patient.

Dans ce contexte, le présent projet s'inscrit dans le domaine de la prédiction de l'efficacité des médicaments anticancéreux à partir de données génomiques. Il repose sur l'exploitation du jeu de données Genomics of Drug Sensitivity in Cancer (GDSC), une ressource de référence qui combine des profils moléculaires de lignées cellulaires cancéreuses avec des mesures quantitatives de sensibilité aux traitements.

1.2 Organisme d'accueil

Ce projet a été réalisé dans le cadre du Master Excellence en Intelligence Artificielle (MEIA) de la Faculté des Sciences Ben M'Sick (FSBM) de l'Université Hassan II de Casablanca. Le Master MEIA vise à former des experts capables de développer des solutions innovantes en intelligence artificielle appliquée à divers domaines, notamment la bioinformatique et la santé numérique.

Le projet a été encadré par Dr. Ichrak BENAMRI, enseignante-chercheuse spécialisée en bio-informatique et intelligence artificielle appliquée aux sciences de la vie. Ce travail s'inscrit

dans le module de Bio-informatique, qui explore les applications de l'IA et du Machine Learning pour résoudre des problématiques complexes dans le domaine biomédical.

1.3 Problématique et besoins

La principale problématique abordée dans ce projet concerne la variabilité de la réponse aux traitements anticancéreux. Un même médicament peut être efficace chez certains patients et inefficace, voire toxique, chez d'autres. Cette hétérogénéité thérapeutique représente un défi majeur en oncologie et souligne le besoin urgent de développer des approches prédictives personnalisées.

Plusieurs besoins scientifiques et cliniques ont motivé ce projet. Premièrement, il existe un besoin de prédiction fiable de la sensibilité des cancers aux médicaments avant l'administration du traitement, permettant ainsi d'éviter des thérapies inefficaces et potentiellement toxiques. Deuxièmement, l'identification de biomarqueurs génomiques associés à la réponse thérapeutique est essentielle pour comprendre les mécanismes de résistance et développer de nouvelles stratégies thérapeutiques. Troisièmement, le développement de modèles computationnels exploitables est nécessaire pour traduire les données génomiques complexes en informations cliniquement actionnables.

1.4 Objectifs

L'objectif général de ce projet est de développer un système de prédiction de l'efficacité des médicaments anticancéreux basé sur le Machine Learning, permettant d'améliorer la sélection des traitements en oncologie et de contribuer à la médecine personnalisée.

Les objectifs spécifiques comprennent l'exploitation du jeu de données GDSC pour extraire et prétraiter les informations génomiques et pharmacologiques pertinentes, l'implémentation et la comparaison de plusieurs algorithmes de Machine Learning (Régression linéaire, Random Forest, Support Vector Regression) pour la prédiction de la sensibilité aux médicaments, l'évaluation rigoureuse des performances des modèles à l'aide de métriques standards (RMSE, R^2, MAE), et l'identification des caractéristiques biologiques les plus prédictives de la réponse thérapeutique.

1.5 Résultats attendus et impact

Les résultats attendus de ce projet incluent le développement de modèles prédictifs performants capables d'estimer la sensibilité des lignées cellulaires cancéreuses aux médicaments anticancéreux, l'identification de biomarqueurs génomiques associés à la réponse thérapeutique, et une méthodologie reproductible et documentée pour l'analyse de données pharmacogénomiques.

L'impact de ce projet se situe à plusieurs niveaux. Sur le plan scientifique, il contribue à l'avancement des connaissances en pharmacogénomique computationnelle et démontre le

potentiel des approches de Machine Learning pour la prédiction de la réponse aux traitements. Sur le plan clinique, ce travail ouvre la voie vers une médecine de précision en oncologie, permettant une sélection plus rationnelle des traitements basée sur les caractéristiques moléculaires des tumeurs. Sur le plan méthodologique, ce projet illustre l'intégration réussie de la bioinformatique et de l'intelligence artificielle pour résoudre des problématiques complexes en santé.

1.6 Structure du rapport

Ce rapport est organisé en plusieurs chapitres reflétant la progression logique du projet. Le Chapitre 1 présente le cahier des charges et le déroulement du projet, incluant les problématiques, objectifs, et la méthodologie de gestion adoptée. Le Chapitre 2 expose l'étude bibliographique, couvrant les concepts de base, la documentation des données GDSC, et les projets similaires dans le domaine. Le Chapitre 3 offre une vue générale du système, décrivant l'architecture, les composants, et les choix méthodologiques relatifs aux modèles de Machine Learning et aux datasets. Le Chapitre 4 détaille l'implémentation et les résultats obtenus, incluant l'environnement technique, les performances des modèles, et l'interprétation des résultats. Enfin, le Chapitre 5 présente la conclusion générale et les perspectives, rappelant les objectifs, synthétisant les résultats, et discutant de l'impact du projet ainsi que des pistes d'amélioration futures.

Chapitre 2

Cahier de charges et déroulement du projet

2.1 Cahier de charges

2.1.1 Problématiques et Besoins

Problématiques scientifiques

La première problématique concerne l'hétérogénéité tumorale. Les cancers présentent une grande variabilité génétique et moléculaire, rendant difficile la prédiction de la réponse thérapeutique. Cette diversité biologique constitue un défi majeur pour le développement de modèles prédictifs fiables.

La deuxième problématique est liée au coût élevé des essais cliniques. Le développement de nouveaux médicaments anticancéreux est un processus long et coûteux, avec un taux d'échec important. Il est donc crucial de développer des méthodes permettant d'identifier les candidats-médicaments les plus prometteurs en amont.

La troisième problématique concerne la personnalisation du traitement. Il existe un besoin urgent de développer des approches permettant d'identifier le traitement le plus adapté pour chaque profil de cancer, en tenant compte des caractéristiques moléculaires spécifiques de la tumeur.

Enfin, la quatrième problématique porte sur le volume et la complexité des données. Les données biologiques sont multidimensionnelles et complexes, nécessitant des méthodes d'analyse avancées capables d'extraire les informations pertinentes pour la prédiction.

Besoins identifiés

Quatre besoins principaux ont été identifiés pour ce projet. Le premier est un besoin prédictif : développer un modèle capable de prédire avec précision la sensibilité d'une lignée cellulaire à un médicament donné. Le deuxième est un besoin comparatif : évaluer et comparer les performances de différents algorithmes de Machine Learning pour identifier l'approche la plus performante. Le troisième est un besoin interprétatif : identifier les caractéristiques biologiques les plus importantes pour la prédiction afin de mieux comprendre les mécanismes de réponse aux médicaments. Le quatrième est un besoin méthodologique : établir un pipeline reproductible et

documenté pour l'analyse de données biologiques, pouvant servir de référence pour de futurs projets.

2.1.2 Objectifs

Objectif général

L'objectif général de ce projet est de développer un système de prédiction de l'efficacité des médicaments anticancéreux basé sur le Machine Learning, permettant d'améliorer la sélection des traitements en oncologie et de contribuer à la médecine personnalisée.

Objectifs spécifiques

Le premier objectif spécifique concerne l'acquisition et le prétraitement des données. Il s'agit de collecter les datasets GDSC et CCLE, de nettoyer et normaliser les données, d'effectuer une analyse exploratoire des données (EDA), et d'identifier et traiter les valeurs manquantes de manière appropriée.

Le deuxième objectif spécifique porte sur le développement des modèles prédictifs. Nous devons implémenter au moins trois algorithmes de Machine Learning différents, entraîner les modèles sur les données d'apprentissage, optimiser les hyperparamètres des modèles pour améliorer leurs performances, et valider les modèles sur un ensemble de test indépendant.

Le troisième objectif spécifique concerne l'évaluation et la comparaison des modèles. Il s'agit de calculer les métriques de performance (RMSE, R^2, MAE), de comparer les performances des différents modèles de manière rigoureuse, d'analyser les forces et faiblesses de chaque approche, et d'identifier le modèle le plus performant pour la tâche de prédiction.

Le quatrième objectif spécifique porte sur l'analyse et l'interprétation des résultats. Nous devons interpréter les résultats d'un point de vue biologique, identifier les caractéristiques les plus prédictives, discuter les limites et perspectives du projet, et proposer des pistes d'amélioration concrètes pour de futurs travaux.

2.2 Déroulement du projet

2.2.1 GANTT

Le projet s'étend sur une période de 25 jours, du 29 décembre 2025 au 30 janvier 2026, et est structuré en cinq phases séquentielles coordonnées par Hajar ELKHALIDI en tant que représentante et responsable du suivi global du projet.

Tâche	Responsable	29/12-03/01	04/01-09/01	10/01-15/01	16/01-30/01
Recherche & Introduction	Hamza RBIB				
Données & Cahier des charges	Hajar BENTAIB				
Machine Learning	Imrane TAYA				
Analyse & Finalisation	Hajar ELKHALIDI				
Coordination & Suivi continu	Hajar ELKHALIDI				
Présentation finale (vidéo)	Tous				

TABLE 2.1 – Diagramme de GANTT du projet

2.2.2 Distribution de rôles

L'équipe projet est composée de quatre membres, avec Hajar ELKHALIDI assurant la coordination générale en plus de son rôle spécifique. Le Tableau 2.2 présente en détail la répartition des rôles et des responsabilités au sein de l'équipe.

Membre	Rôle principal	Responsabilités détaillées
Hamza RBIB	Recherche scientifique & Introduction	Recherche bibliographique approfondie sur PubMed et bases scientifiques, définition claire de la problématique, rédaction de l'Abstract et du Résumé, rédaction complète de l'Introduction générale, compilation et formatage des références scientifiques
Hajar BENTAIB	Données & Prétraitement	Acquisition des datasets biologiques (GDSC, CCLE), nettoyage et normalisation des données, exploration et visualisation des données, sélection des variables pertinentes, rédaction du cahier des charges technique
Imrane TAYA	Machine Learning	Sélection et justification des algorithmes ML, implémentation et entraînement des modèles, optimisation rigoureuse des hyperparamètres, évaluation et comparaison des performances, documentation technique complète du code
Hajar EL KHALIDI	Représentante, Coordination générale & Analyse	Suivi continu de toutes les phases du projet, coordination entre les membres de l'équipe, analyse approfondie des résultats obtenus, interprétation biologique des prédictions, discussion des limites et perspectives, rédaction de la conclusion générale, finalisation et harmonisation du rapport, préparation de la présentation finale

TABLE 2.2 – Distribution des rôles au sein de l'équipe

2.2.3 Méthodologie de gestion

Le projet adopte une méthodologie en cascade séquentielle avec une coordination transversale assurée par la représentante du projet. Cette approche permet à la fois une spécialisation des tâches et une cohérence globale maintenue par un suivi continu.

Les principes directeurs de cette gestion incluent la séquentialité avec coordination : chaque phase est menée par un membre spécifique tout en étant suivie par la représentante du projet qui assure la cohérence globale. La communication continue : des échanges réguliers permettent

d'identifier rapidement les difficultés et d'apporter les ajustements nécessaires. La validation progressive : chaque livrable est validé avant le passage à la phase suivante, garantissant la qualité à chaque étape.

Pour faciliter le travail collaboratif, plusieurs outils numériques sont utilisés : Kaggle pour la gestion de versions, Overleaf pour la rédaction collaborative, Google Drive pour le partage des données, et WhatsApp pour la communication quotidienne.

Chapitre 3

Étude bibliographique

3.1 Définitions des standards et des concepts de base

3.1.1 Lignées cellulaires cancéreuses

Les lignées cellulaires utilisées représentent différents types de cancers humains et constituent des modèles expérimentaux largement utilisés pour étudier la réponse aux traitements anticancéreux *in vitro*. Chaque lignée est identifiée de manière unique par un identifiant `COSMIC_ID`, garantissant une correspondance fiable entre les différents fichiers.

Les principales caractéristiques biologiques associées aux lignées sont : `CANCER_TYPE` (classification du cancer selon la nomenclature TCGA comme BRCA, COAD/READ, HNSC), `GDSC_TISSUE_1` (tissu d'origine de la lignée cellulaire, reflétant le contexte biologique initial), `MSI_STATUS` (statut d'instabilité microsatellitaire, indicateur important de l'hétérogénéité génomique), et `Growth Properties` (mode de croissance cellulaire, adhérente ou en suspension, pouvant influencer la réponse aux traitements). Ces variables permettent d'intégrer la diversité biologique des cancers dans le processus de prédiction.

3.1.2 Médicaments anticancéreux

Les composés pharmacologiques testés couvrent un large éventail de mécanismes d'action. Chaque médicament est caractérisé par `DRUG_ID` et `DRUG_NAME` (identifiants uniques), `TARGET` (cibles moléculaires principales comme EGFR, TOP1), et `TARGET_PATHWAY` (voies biologiques affectées par le médicament comme DNA replication, PI3K/MTOR signaling). Ces informations sont essentielles pour relier la sensibilité observée aux mécanismes biologiques sous-jacents.

3.1.3 Mesures de réponse aux traitements

La réponse des lignées cellulaires aux médicaments est mesurée à l'aide de deux indicateurs standards en pharmacologie. Le premier est `LN_IC50`, le logarithme naturel de la concentration nécessaire pour inhiber 50% de la croissance cellulaire. Cette variable est utilisée comme variable cible du modèle, car elle quantifie directement l'efficacité du médicament. Le second est `AUC` (Area Under the Curve), l'aire sous la courbe dose-réponse, fournissant une mesure globale de la sensibilité. Ces mesures sont issues d'un ajustement de modèles dose-réponse non linéaires.

3.2 Documentation nécessaire : Modèles IA, statistiques et enquêtes existantes

3.2.1 Source des données

Les jeux de données utilisés proviennent de la base *Genomics of Drug Sensitivity in Cancer (GDSC)* [1], développée par le Wellcome Sanger Institute. Cette base constitue une référence internationale en oncologie computationnelle et en bioinformatique, et elle est largement utilisée dans la littérature scientifique.

Les données sont accessibles publiquement via la plateforme officielle GDSC [1] et sont accompagnées de descriptions détaillées des protocoles expérimentaux. Trois fichiers principaux ont été exploités : `GDSC2_fitted_dose_response_25Feb20.csv` (données de réponse aux médicaments), `Cell_Lines_Details.xlsx` (informations biologiques sur les lignées cellulaires), et `screened_compounds_rel_8.2.csv` (informations pharmacologiques sur les composés).

3.2.2 Structure des données

Dans le cadre de ce projet, l'objectif principal est de prédire l'efficacité de médicaments anticancéreux à partir de données biologiques et pharmacologiques issues de lignées cellulaires humaines. La qualité et la préparation des données constituent une étape fondamentale, car les performances des modèles de Machine Learning dépendent fortement de la pertinence et de la fiabilité des informations utilisées.

Les données exploitées combinent des mesures expérimentales de sensibilité aux médicaments avec des caractéristiques biologiques décrivant les lignées cellulaires et les composés testés. Le jeu de données final obtenu comprend 135 242 observations, chacune correspondant à une interaction lignée-médicament.

3.2.3 Prétraitement et nettoyage des données

Harmonisation et renommage

Les colonnes issues de différentes sources ont été renommées et harmonisées afin d'assurer une cohérence globale et de faciliter les opérations de fusion.

1. `https://www.cancerrxgene.org/`

Gestion des valeurs manquantes

Les valeurs manquantes ont été traitées selon leur nature. D'une part, les observations sans valeurs pour `LN_IC50` ou `AUC` ont été supprimées. D'autre part, les valeurs manquantes catégorielles ont été remplacées par la modalité `Unknown`, afin de conserver un maximum d'informations.

Suppression des redondances

Certaines colonnes dupliquées issues des opérations de fusion (par exemple, `DRUG_NAME_x` et `DRUG_NAME_y`) ont été supprimées après vérification de leur équivalence. Cette étape permet de réduire la dimensionalité inutile et d'éviter toute confusion lors de l'analyse.

Nettoyage numérique

Les variables numériques ont été converties explicitement en type `float` et les valeurs de `AUC` ont été arrondies afin d'améliorer la lisibilité sans altérer l'information scientifique.

3.2.4 Sélection des variables et préparation pour le Machine Learning

3.2.5 Normalisation et encodage

Afin de rendre les données compatibles avec les algorithmes de Machine Learning, plusieurs transformations ont été appliquées. Les variables numériques ont été standardisées à l'aide d'un `StandardScaler`. Les variables catégorielles ont été transformées par *One-Hot Encoding*. Un `ColumnTransformer` a été utilisé pour assurer une transformation reproductible et cohérente. Les données finales sont ainsi entièrement numériques et prêtes pour l'entraînement des modèles.

3.2.6 Analyse exploratoire et visualisations

Une analyse exploratoire approfondie a été réalisée afin de mieux comprendre la structure des données. Cette analyse comprend l'étude des distributions de `LN_IC50` et `AUC`, la comparaison de la sensibilité aux traitements selon les types de cancer et les tissus d'origine, ainsi que l'analyse de la corrélation entre les variables numériques. Ces visualisations permettent de mettre en évidence l'impact du contexte biologique sur l'efficacité des médicaments.

Distributions des variables de réponse

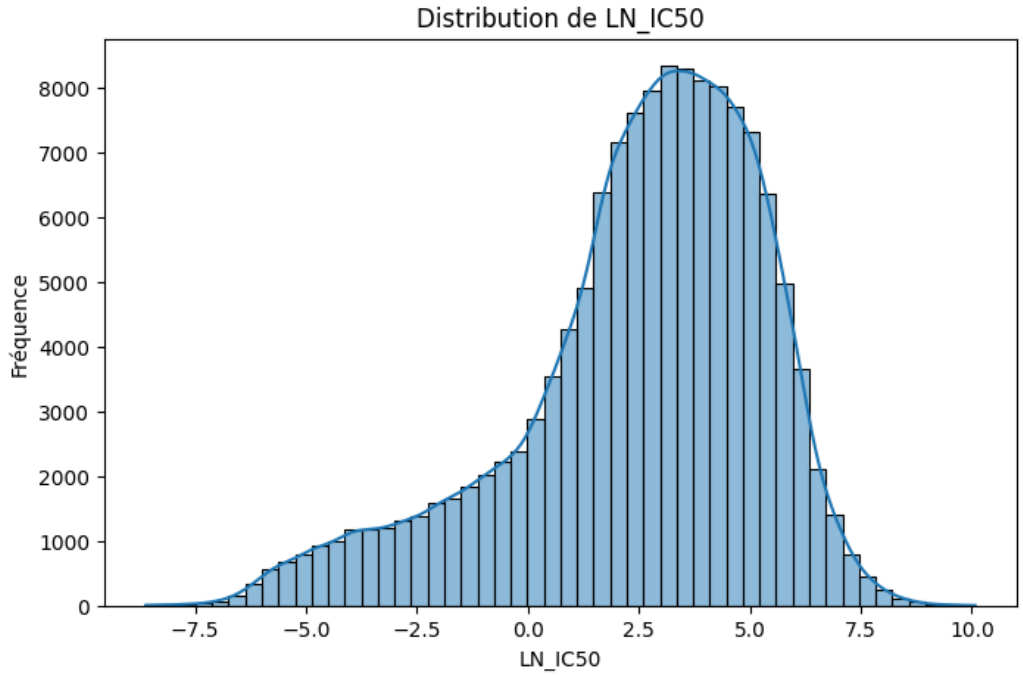


FIGURE 3.1 – Distribution de `LN_IC50` (histogramme et densité).

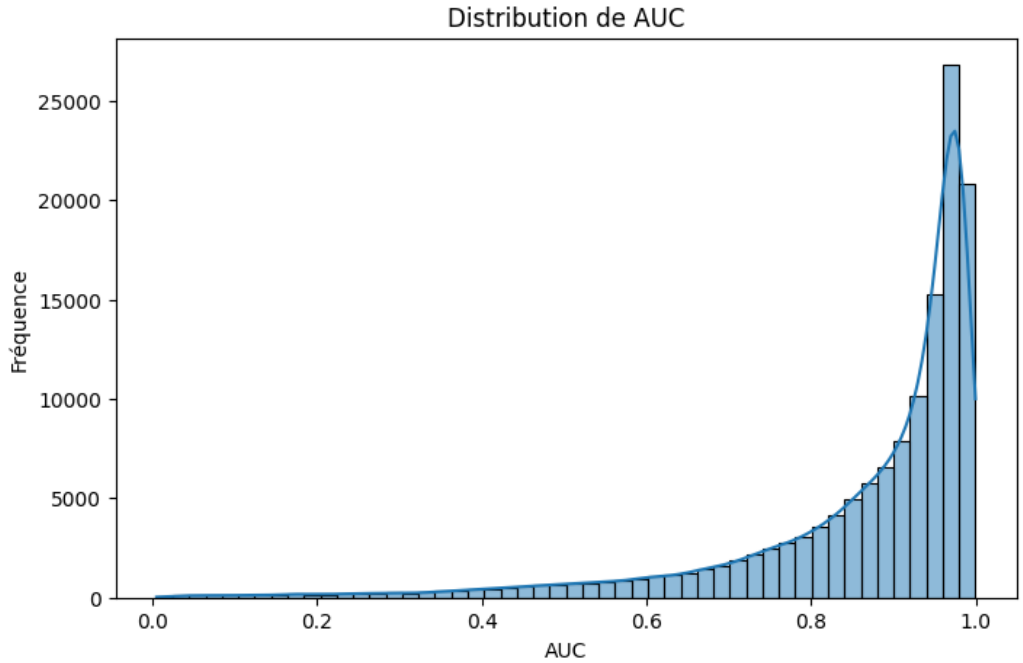


FIGURE 3.2 – Distribution de `AUC` (histogramme et densité).

La Figure 3.1 présente la distribution de la variable cible `LN_IC50`. Cette visualisation permet de vérifier la dispersion des réponses, d'identifier d'éventuelles asymétries et de détecter la présence de valeurs extrêmes pouvant influencer l'apprentissage des modèles.

La Figure 3.2 illustre la distribution de AUC, une mesure globale de la sensibilité. Elle complète l'analyse de LN_IC50 et aide à comprendre la variabilité générale des profils dose-réponse dans le dataset.

Sensibilité selon le contexte biologique : type de cancer et tissu

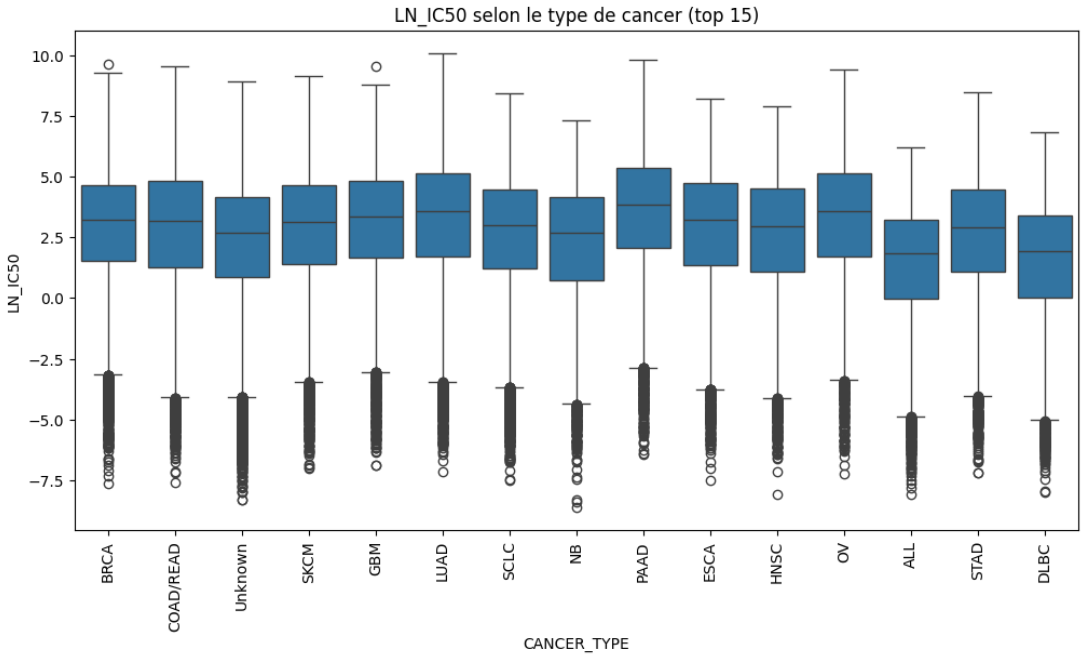


FIGURE 3.3 – Distribution de LN_IC50 selon le type de cancer (CANCER_TYPE).

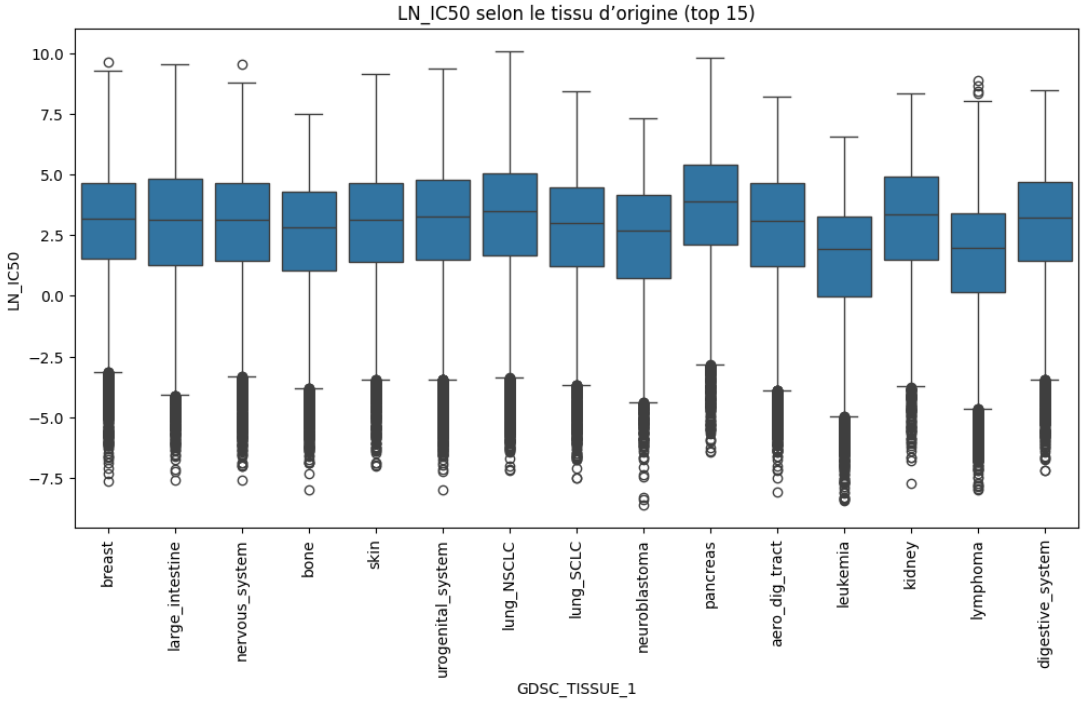


FIGURE 3.4 – Distribution de LN_IC50 selon le tissu d'origine (GDSC_TISSUE_1).

La Figure 3.3 met en évidence une variabilité de la sensibilité selon les classes tumorales. La présence de médianes et de dispersions différentes suggère que le contexte biologique associé au type de cancer peut contribuer à expliquer les différences de réponse aux traitements.

La Figure 3.4 confirme également un effet “tissu” sur la réponse aux médicaments. Cette observation est cohérente avec l’hypothèse que l’origine biologique des lignées cellulaires influence la sensibilité, et justifie l’intégration de ces variables catégorielles dans la modélisation prédictive.

Relation et corrélation entre variables numériques

La Figure 3.5 explore la relation entre `AUC` et `LN_IC50`. Elle permet d’évaluer si ces deux mesures de sensibilité apportent des informations complémentaires ou redondantes, ce qui est utile pour décider de conserver (ou non) `AUC` dans les variables explicatives.

La Figure 3.6 synthétise les corrélations entre variables numériques. Elle aide à repérer des dépendances fortes, susceptibles d’induire de la redondance, et peut guider la sélection de variables ou l’interprétation des résultats des modèles.

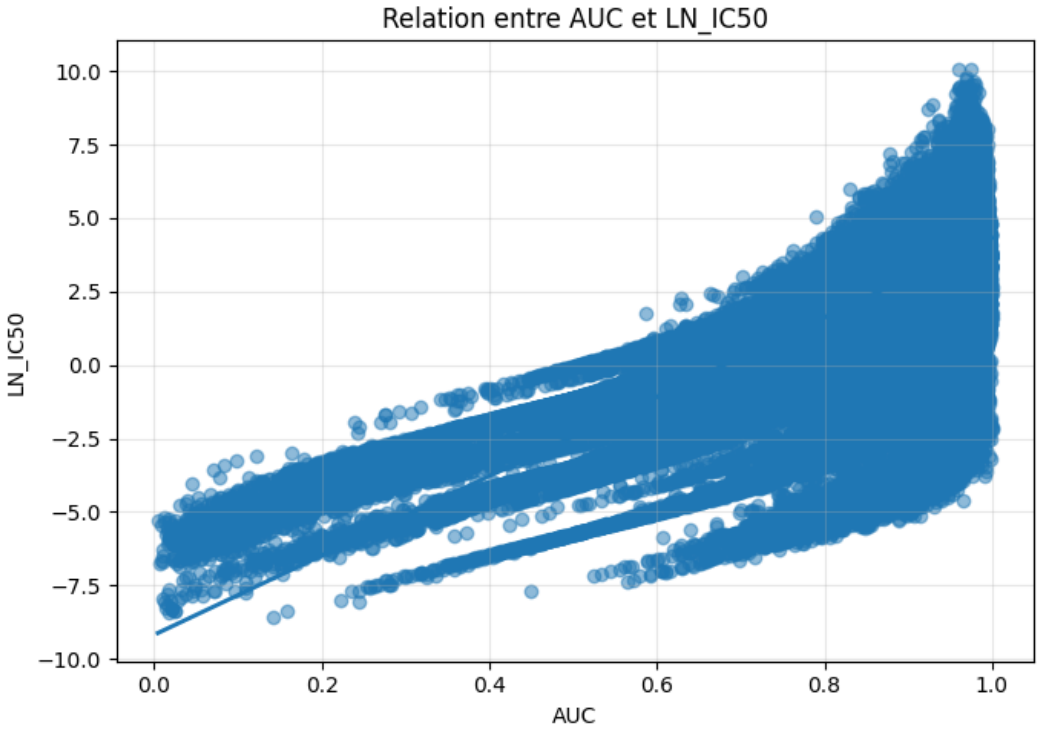


FIGURE 3.5 – Relation entre `AUC` et `LN_IC50` (nuage de points).

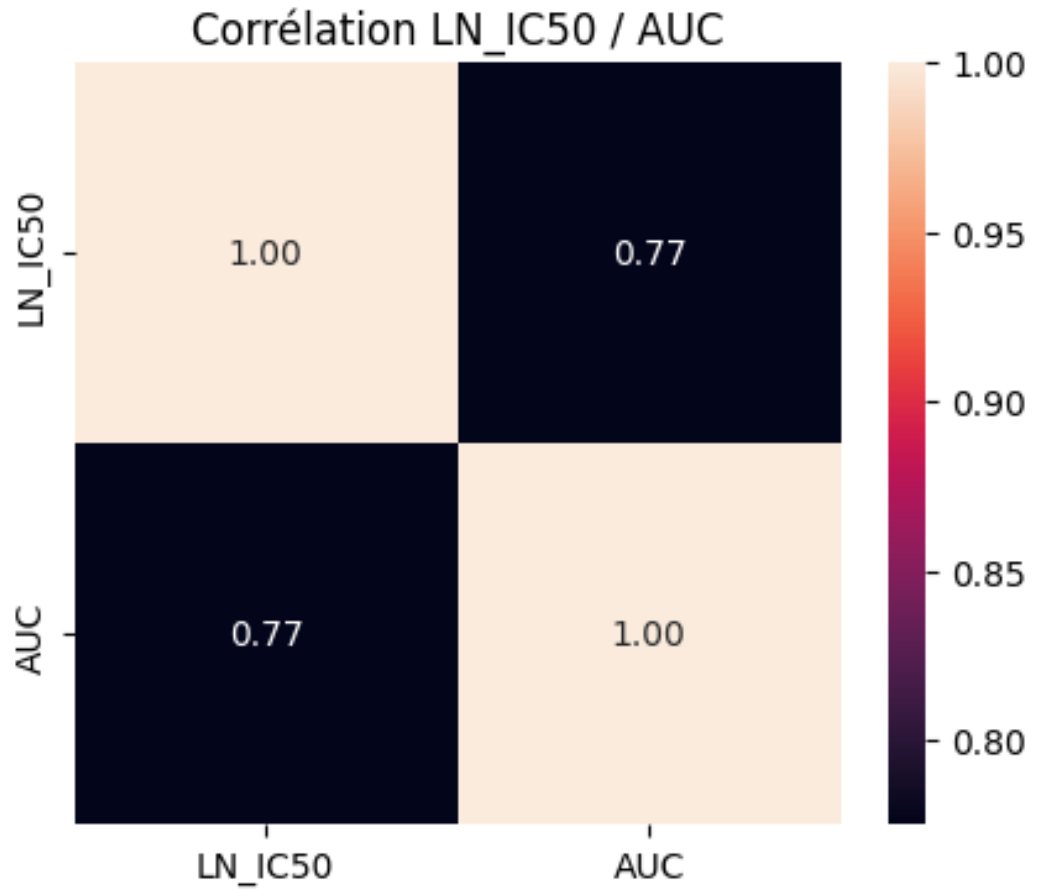


FIGURE 3.6 – Matrice de corrélation des variables numériques (heatmap).

3.2.7 Ressources et reproductibilité

Les graphiques présentés dans la section précédente ont été générés à partir du notebook d'analyse (annexe technique), puis exportés en images afin d'être intégrés au rapport.

- **Source officielle des données :** plateforme GDSC (Wellcome Sanger Institute) [1].
- **Annexe technique (interne) :** notebook Kaggle utilisé pour le prétraitement et l'EDA .
- **Dossier figures :** `figures/` contenant les exports des graphiques (format PNG, haute résolution).

3.3 Autres projets similaires ou en relation à l'objectif

Le domaine de la prédiction de la réponse aux médicaments anticancéreux a connu un développement important ces dernières années, avec l'émergence de nombreux projets et méthodes computationnelles. Cette section présente les principales approches et projets qui partagent des objectifs similaires avec notre travail.

3.3.1 Évaluation critique des prédicteurs précliniques

Wong et collaborateurs [2] ont réalisé une évaluation critique des prédicteurs précliniques de l'efficacité des médicaments anticancéreux. Leur étude met l'accent sur l'importance de la puissance nanomolaire comme critère de sélection des agents candidats. Cette analyse a permis d'établir des standards méthodologiques pour l'évaluation de l'efficacité des médicaments en phase préclinique, soulignant notamment les limites des approches traditionnelles et la nécessité de critères de sélection plus rigoureux.

Les auteurs ont démontré que la simple observation d'une activité anticancéreuse in vitro ne suffit pas pour prédire le succès clinique d'un médicament. Cette étude a établi un cadre conceptuel important pour comprendre les exigences nécessaires à une prédiction fiable de l'efficacité thérapeutique, ce qui reste pertinent pour notre approche de modélisation prédictive.

3.3.2 Régression multi-cible et Support Vector Regression

Brindha et collaborateurs [3] ont développé une approche innovante combinant la régression multi-cible (Multi Target Regression, MTR) et la Support Vector Regression (SVR) pour prédire avec précision l'efficacité de multiples médicaments anticancéreux. Leur méthodologie présente une similarité directe avec notre projet dans le choix des algorithmes de Machine Learning.

Cette étude a démontré que l'utilisation conjointe de MTR et SVR permet d'améliorer significativement la précision des prédictions par rapport aux approches mono-algorithme traditionnelles. Les auteurs ont traité simultanément plusieurs médicaments, exploitant les corrélations entre les réponses à différents traitements pour améliorer les performances globales du modèle. Cette approche comparative d'algorithmes constitue une référence méthodologique importante

pour notre travail, particulièrement dans l'évaluation et la comparaison des performances de différentes techniques de régression.

3.3.3 Apprentissage à partir de voies moléculaires dérivées du génome

Plus récemment, Dong et collaborateurs [4] ont proposé une approche novatrice pour la prédiction personnalisée du potentiel anticancéreux de médicaments non-oncologiques. Leur méthodologie repose sur l'apprentissage à partir de voies moléculaires dérivées du génome, représentant une avancée significative dans l'intégration de données génomiques complexes.

Cette étude se distingue par son objectif de repositionnement de médicaments existants vers des applications anticancéreuses, une approche prometteuse pour accélérer le développement thérapeutique. Les auteurs ont développé un framework d'apprentissage automatique capable d'identifier des médicaments non-oncologiques ayant un potentiel thérapeutique contre le cancer en analysant les interactions entre les profils moléculaires des patients et les mécanismes d'action des médicaments. Cette perspective de médecine personnalisée rejoint directement l'objectif de notre projet de contribuer à une approche thérapeutique plus ciblée et individualisée.

3.3.4 Positionnement de notre projet

Notre projet s'inscrit dans la continuité de ces travaux tout en adoptant une approche distinctive. Comme l'étude de Brindha et al. [3], nous privilégions une comparaison rigoureuse de plusieurs algorithmes de Machine Learning classiques (Régression linéaire, Random Forest, Support Vector Regression) appliqués aux données GDSC.

Contrairement aux approches Deep Learning plus complexes, notre méthodologie privilégie la transparence et l'interprétabilité des modèles, un aspect souligné comme crucial par Wong et al. [2] pour la validation préclinique. Tout en maintenant une performance prédictive compétitive, cette approche permet une meilleure compréhension des mécanismes biologiques sous-jacents, s'alignant avec la vision de médecine personnalisée proposée par Dong et al. [4], et facilite l'adoption clinique potentielle des résultats.

Notre contribution se situe ainsi à l'intersection de ces différentes approches, combinant rigueur méthodologique, interprétabilité des résultats et pertinence clinique pour la prédiction de l'efficacité des médicaments anticancéreux.

Chapitre 4

Vue générale

4.1 Architecture du système

Le livrable principal du projet est un **pipeline de science des données** implémenté dans un notebook Python. Ce pipeline transforme des données brutes issues de GDSC2 (dose–réponse), des métadonnées de lignées cellulaires et des informations sur les médicaments en un jeu de données exploitable, puis entraîne des modèles de régression pour prédire la sensibilité au traitement.

L'architecture logique suit les étapes suivantes :

1. **Ingestion des données** : chargement robuste des fichiers Excel/CSV (détection de l'encodage et du séparateur si nécessaire).
2. **Nettoyage et standardisation** : homogénéisation des noms de colonnes, conversion des identifiants (`COSMIC_ID`, `DRUG_ID`) et des variables numériques (`LN_IC50`, `AUC`), suppression des doublons `(COSMIC_ID, DRUG_ID)`.
3. **Fusion contrôlée** : jointure *many-to-one* sur `COSMIC_ID` (lignée) et `DRUG_ID` (médicament), avec validation et déduplication préventive des tables de référence.
4. **Ingénierie de variables** : extraction d'informations simples sur les cibles (première cible, nombre de cibles) et création de variables d'interaction (ex. tissu $\times$ voie biologique).
5. **Prétraitement** : imputation (médiane pour numériques, `Unknown` pour catégorielles), normalisation des variables numériques, encodage des variables catégorielles (One-Hot pour modèles linéaires, Ordinal/One-Hot pour modèles à base d'arbres).
6. **Entraînement et évaluation** : validation croisée **GroupKFold** avec groupement par `COSMIC_ID` afin de mesurer la généralisation sur des lignées jamais vues, et comparaison à des **baselines** (moyenne par médicament / par lignée).

Cette structuration permet d'isoler clairement les responsabilités (préparation des données, construction des features, apprentissage et évaluation) et de limiter les risques de fuite d'information lors de l'évaluation.

4.2 Composants du système

Le notebook s'organise en composants fonctionnels, chacun correspondant à un bloc du pipeline :

- **Chargement robuste** : fonctions de lecture des fichiers (`load_table`, `load_csv_robust`) pour gérer différents formats et encodages.
- **Nettoyage / contrôle d'intégrité** : standardisation des colonnes, conversion de types, suppression des valeurs impossibles, contrôle d'unicité des clés (`assert_or_fix_unique`).
- **Fusion et dataset final** : jointures sur `COSMIC_ID` et `DRUG_ID`, génération et sauvegarde du dataset nettoyé (`gdsc_clean_cosmic_only.csv`).
- **EDA** : visualisations des distributions de `LN_IC50` et `AUC`, corrélation, et boxplots par catégories majeures.
- **Feature engineering** : création de variables dérivées (`TARGET_FIRST`, `NUM_TARGETS`, `CONC_RANGE`) et interactions (ex. `TISSUE_PATHWAY`).
- **Prétraitement** : `ColumnTransformer` + `Pipeline` (imputation, standardisation, encodage).
- **Modélisation** : entraînement de plusieurs régressions (linéaires régularisées et ensembles d'arbres).
- **Évaluation** : validation croisée groupée + calcul des métriques (RMSE, MAE, R^2) et export des résultats (`benchmark_COSMIC_ID.csv`, `baselines_COSMIC_ID.csv`).

La Figure d'ensemble est donc celle d'un pipeline « data → features → modèles → métriques », conçu pour être reproductible et extensible (ajout de nouvelles features, d'autres modèles ou d'autres schémas de validation).

4.3 Diagrammes UML

Le notebook ne génère pas directement de diagrammes UML, mais sa structure se prête à une représentation en diagramme d'activité et en diagramme de composants. Ci-dessous, les deux schémas qui mettent en évidence le caractère modulaire du travail : chaque bloc peut évoluer indépendamment (par exemple en ajoutant des données omiques, ou en remplaçant un modèle par un autre) sans réécrire l'ensemble du pipeline. :

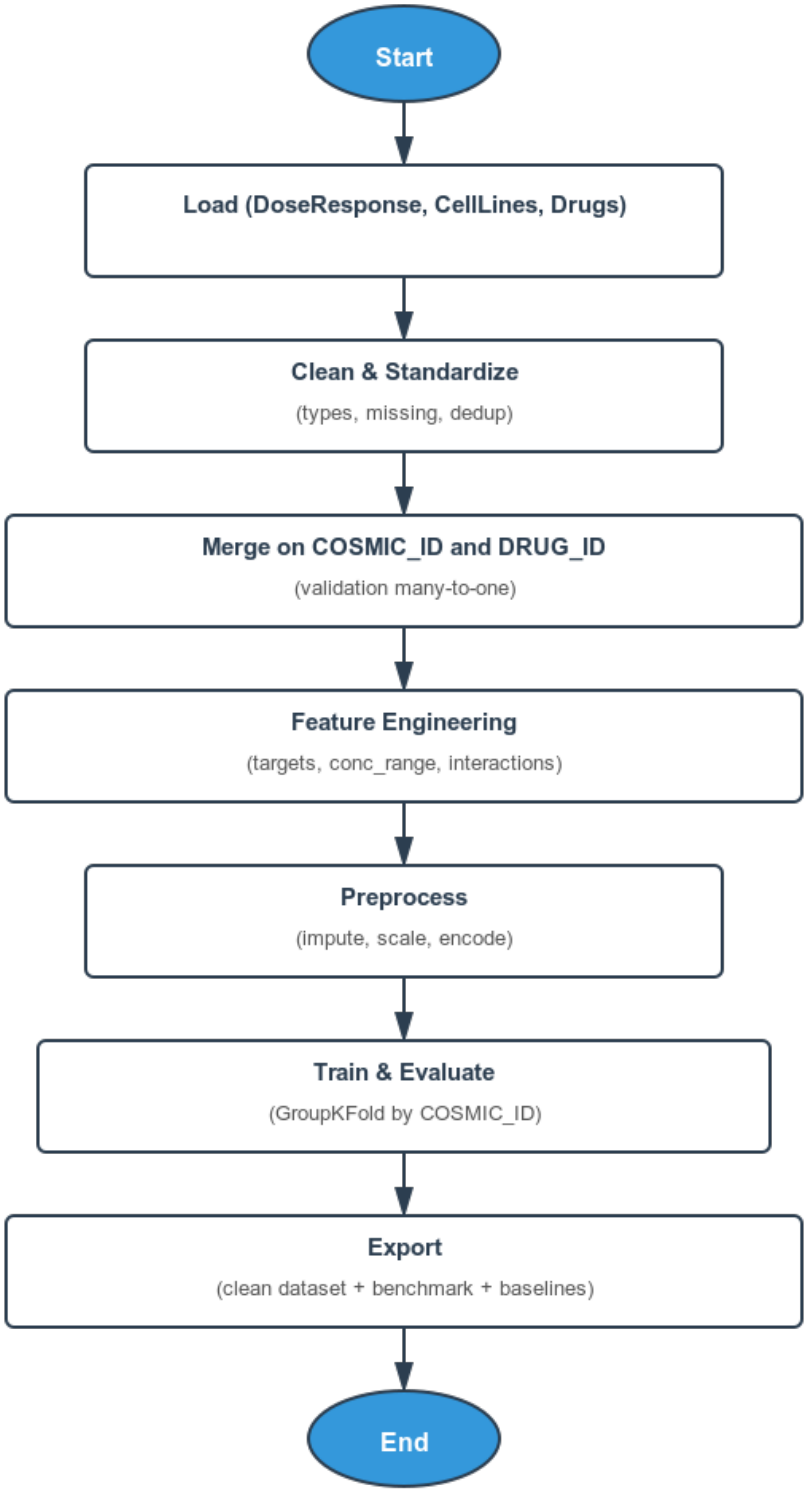


FIGURE 4.1 – Diagramme d'activité (vue pipeline).

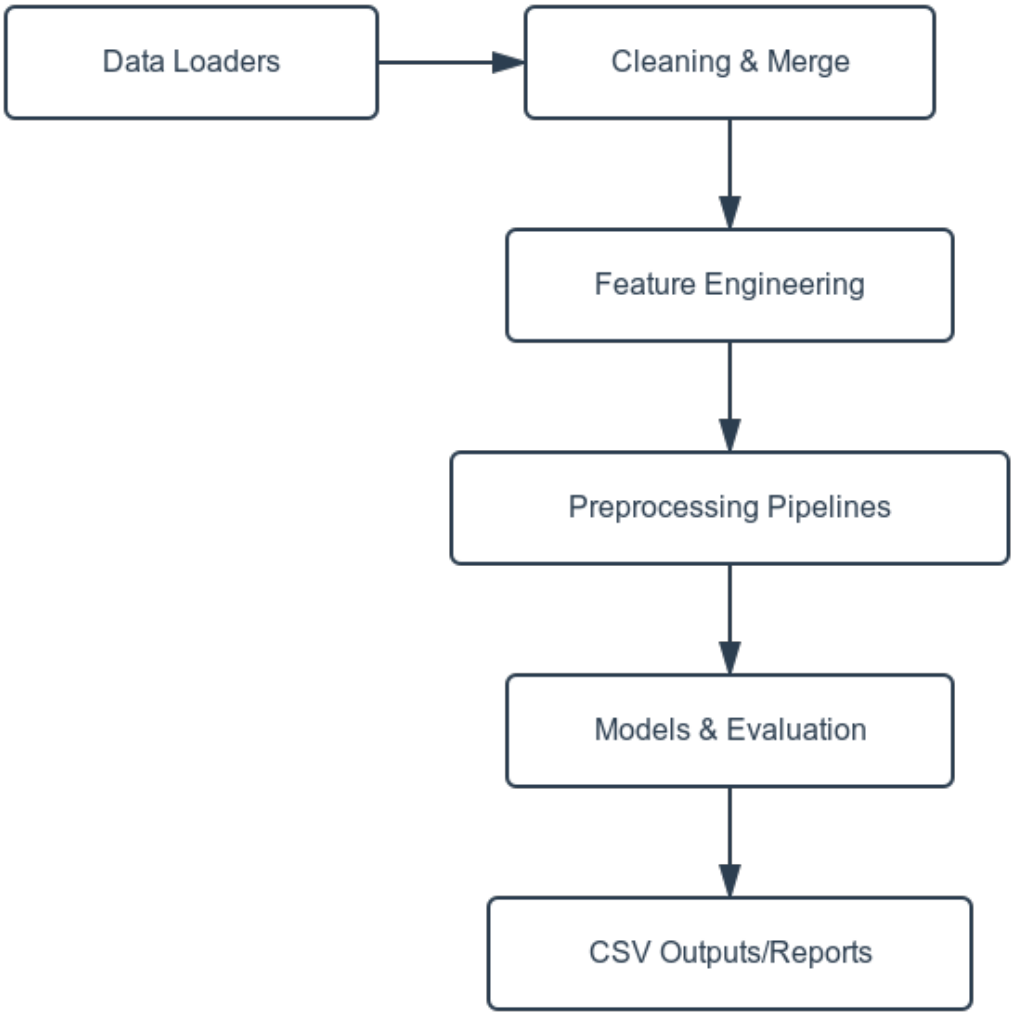


FIGURE 4.2 – Diagramme de composants (vue logique).

4.4 Choix des modèles AI et justification des choix

Le notebook implémente plusieurs familles de modèles de régression afin de comparer des compromis différents (capacité non-linéaire, robustesse, interprétabilité) :

- **Ridge** : régression linéaire régularisée (ℓ_2). Elle sert de modèle de référence stable et rapide, particulièrement adaptée quand l'encodage One-Hot produit de nombreuses variables.
- **ElasticNet** : combinaison de régularisations ($\ell_1 + \ell_2$) utile lorsque certaines variables sont redondantes et que l'on souhaite une forme de sélection de variables.
- **RandomForestRegressor** : ensemble d'arbres par *bagging*, capable de modéliser des relations non linéaires et des interactions entre variables sans hypothèses fortes.
- **ExtraTreesRegressor** : variante plus aléatoire des forêts, souvent robuste au bruit et efficace lorsque les variables sont hétérogènes (numériques + catégorielles).
- **HistGradientBoostingRegressor** : boosting d'arbres histogrammé (rapide sur grands jeux de données), utile pour capturer des non-linéarités complexes.

Ce choix multi-modèles a deux objectifs : (i) obtenir une performance prédictive satisfaisante, et (ii) éviter de conclure trop vite sur un seul algorithme, surtout lorsque l'évaluation est réalisée avec un schéma strict (GroupKFold par `COSMIC_ID`) qui peut pénaliser certains modèles.

4.5 Choix des datasets d'entraînements

Le pipeline s'appuie sur des ressources issues de GDSC2 [1] et des tables associées :

- **Dose–réponse (GDSC2)** : table principale contenant, pour chaque couple (`COSMIC_ID`, `DRUG_ID`), des mesures de sensibilité telles que `LN_IC50` (cible) et `AUC` (mesure globale optionnelle).
- **Métadonnées des lignées cellulaires** : informations contextuelles (ex. `GDSC_TISSUE_1`, `CANCER_TYPE`, `MSI_STATUS`, `GROWTH_PROPERTIES`) permettant de modéliser des différences biologiques entre lignées.
- **Informations sur les composés** : attributs du médicament (ex. `TARGET`, `TARGET_PATHWAY`) utilisés pour relier la réponse observée à des mécanismes d'action supposés.

Clés de jointure. Les données sont fusionnées via `COSMIC_ID` (identifiant unique de la lignée) et `DRUG_ID` (identifiant du composé). Le nettoyage supprime les entrées sans `LN_IC50` / `AUC` et déduplique les couples (`COSMIC_ID`, `DRUG_ID`) afin d'obtenir une observation par lignée et par médicament.

Remarque : certaines descriptions de datasets (p.ex. CCLE) peuvent être citées dans la littérature ; dans notre implémentation, la version opérationnelle exploitée dans le notebook correspond aux tables GDSC2 et métadonnées associées, car elles suffisent à établir un pipeline complet et reproductible.

4.6 Architecture réseau

Le notebook se concentre sur la phase **offline** (construction du dataset, entraînement et évaluation). Il n'inclut pas de déploiement réseau à proprement parler. Cependant, si l'on souhaite exposer le modèle pour de l'inférence, une architecture réseau simple et réaliste peut être proposée :

- **Service d'inférence (API REST)** : un microservice (par exemple en Spring Boot [**?**]) recevant en entrée les caractéristiques d'un couple (médicament, lignée) et renvoyant la prédiction de `LN_IC50`.
- **Stockage** : une base de données (ou un stockage objet) pour conserver (i) les jeux de données nettoyés, (ii) les modèles sérialisés (`joblib/pickle`), (iii) les métriques et rapports.
- **Interface utilisateur** : un tableau de bord (web) permettant de comparer les modèles, consulter les performances par sous-groupes (tissus, voies, etc.) et lancer des prédictions.

Cette proposition est cohérente avec les sorties du notebook (fichiers CSV de benchmark et baselines) et permettrait d'industrialiser progressivement le projet sans modifier le cœur de la partie apprentissage.

4.7 Modèles BI

Dans une perspective d'exploitation et de suivi, les sorties du notebook se prêtent à une couche **BI / reporting** (Business Intelligence) :

- **Table « benchmark »** : classement des modèles avec RMSE/MAE/R^2 (moyenne et écart-type sur les folds).
- **Table « baselines »** : performances de références (`MeanBy(DRUG_ID)` et `MeanBy(COSMIC_ID)`) utiles pour détecter des scores artificiellement élevés.

Ces tables peuvent être intégrées dans un tableau de bord (Excel/Power BI/Metabase) pour suivre des indicateurs clés :

- performance globale (RMSE, MAE, R^2) du meilleur modèle ;
- comparaison automatique au baseline `MeanBy(DRUG_ID)` ;
- analyse par sous-groupes biologiques (ex. tissu, type de cancer, voie ciblée) lorsque les données le permettent.

L'intérêt de cette couche BI est de rendre les résultats plus actionnables : on passe d'un notebook expérimental à une visualisation exploitable par un public non technique (biologistes, cliniciens, décideurs).

Chapitre 5

Implémentation et résultats

5.1 Environnement software et hardware

Le développement a été réalisé en Python, dans un environnement de type notebook sur `Kaggle` pour faciliter le travail d'équipe et garder le travail `clean` et organisé.

Logiciels et bibliothèques

- **Python** (notebook) ;
- **Pandas / NumPy** : manipulation des données et opérations numériques ;
- **scikit-learn** : prétraitement (`Pipeline`, `ColumnTransformer`), modèles (Ridge, ElasticNet, RandomForest, ExtraTrees, HistGradientBoosting) et métriques (RMSE, MAE, R^2) ;
- **matplotlib / seaborn** : visualizations EDA (distributions, corrélations, boxplots) ;
- **openpyxl** : lecture de fichiers Excel.

Matériel

Le notebook ne fixe pas explicitement une configuration matérielle : l'entraînement peut s'exécuter sur les ressources (CPU/RAM) fournies par la plateforme Kaggle.

5.2 Résultats

L'évaluation est réalisée en **validation croisée GroupKFold** ($N = 5$ folds dans le notebook) en groupant sur `COSMIC_ID`. Ce choix répond à un objectif méthodologique important : tester la capacité du modèle à généraliser à **de nouvelles lignées cellulaires** à limiter la fuite d'information entre apprentissage et le test.

Métriques

Trois métriques de régression sont calculées à chaque pli puis agrégées :

— **RMSE** : pénalise fortement les grandes erreurs ;

— **MAE** : erreur moyenne absolue, plus robuste aux outliers ;

— R^2 : proportion de variance expliquée.

Baselines

Deux baselines sont calculées avec le même schéma GroupKFold :

— `MeanBy(DRUG_ID)` : prédire la moyenne de `LN_IC50` observée pour le médicament (baseline principale lorsque le split est par lignée) ;

— `MeanBy(COSMIC_ID)` : prédire la moyenne par lignée (utile surtout comme contrôle).

Sorties produites

Le notebook exporte deux fichiers qui synthétisent les résultats :

— `benchmark_COSMIC_ID.csv` : tableau des modèles testés avec `RMSE_mean/std`, `MAE_mean/std` et `R2_mean/std` ;

— `baselines_COSMIC_ID.csv` : performances des baselines.

Remarque. Les valeurs numériques dépendent de l'exécution (version exacte des fichiers, environnement) ; le meilleur modèle correspond à la première ligne du fichier `benchmark_COSMIC_ID.csv` (trié par RMSE croissante).

5.3 Interprétation des résultats

Les résultats doivent être interprétés à la lumière (i) du choix de la cible et (ii) du schéma d'évaluation.

Sens de la cible

La variable `LN_IC50` est un proxy de la sensibilité : une valeur plus faible correspond généralement à une plus grande efficacité du médicament (concentration plus faible requise pour inhiber 50% de la croissance). L'objectif du modèle est donc de prédire correctement cette sensibilité à partir d'informations contextuelles (lignée, tissu, type de cancer) et de mécanisme d'action (cible/voie du médicament).

Pourquoi GroupKFold par `COSMIC_ID` ?

En groupant par lignée, on évite que des observations quasi identiques d'une même lignée se retrouvent à la fois en apprentissage et en test. Ainsi, un bon score indique une capacité à **transférer** vers des lignées non observées, ce qui est plus proche du cas d'usage (prédire la réponse d'un nouveau contexte biologique).

Lecture des baselines

Comparer un modèle à `MeanBy(DRUG_ID)` est essentiel : si un modèle ne dépasse pas cette baseline, cela signifie qu'il n'exploite pas suffisamment les informations sur les lignées pour améliorer la prédiction au-delà de la puissance moyenne du médicament. À l'inverse, une amélioration simultanée (RMSE plus faible, R^2 plus élevé) suggère que les variables biologiques et les interactions ajoutées apportent un signal prédictif.

5.4 Discussion et critiques

Forces

— Pipeline complet : de la fusion des sources à l'évaluation, avec sauvegarde d'artefacts.
— Prétraitement sûr : imputation séparée (numérique vs catégoriel) et validation des jointures (*many-to-one*) pour éviter des erreurs silencieuses.
— Évaluation stricte : GroupKFold par `COSMIC_ID` pour limiter la fuite d'information.
— Comparaison à des baselines : indispensable pour détecter des scores surestimés.

Limites

— **Features limitées** : le notebook exploite surtout des métadonnées (tissus, type de cancer, cibles/voies). L'ajout de données omiques (expression, mutations, CNV) et/ou de descripteurs chimiques (structure du médicament) pourrait améliorer la prédiction.
— **Bruit expérimental** : les mesures dose–réponse peuvent contenir de la variabilité, ce qui limite un plafond de performance.
— **Généralisation** : le split par lignée évalue une généralisation difficile (nouvelle lignée). Un split par médicament (`DRUG_ID`) répondrait à une autre question (nouveau médicament), plus exigeante encore.
— **Interprétabilité** : les modèles d'ensemble (forêts, boosting) sont performants mais moins explicables ; des méthodes d'explicabilité (Permutation Importance, SHAP) seraient pertinentes.

Pistes d'amélioration immédiates

— enrichir les features (omiques / chimie) et comparer différents schémas de validation (par lignée, par médicament, double split) ;
— analyser les erreurs par sous-groupes (tissu, voie ciblée) pour détecter les zones de faiblesse ;
— calibrer et tuner les hyperparamètres via une recherche structurée (Random Search / Bayesian Optimization).

Chapitre 6

Conclusion générale et perspectives

6.1 Bref rappel des objectifs

L'objectif général du projet est de construire un système capable de **prédire la sensibilité à un médicament anticancéreux** à partir de données issues de grandes bases pharmacogénomiques.

Plus précisément, il s'agissait de :

— intégrer et nettoyer des sources hétérogènes (dose–réponse, métadonnées des lignées, informations sur les composés) ;
— construire un jeu de données cohérent centré sur `LN_IC50` ;
— entraîner plusieurs modèles de régression et comparer leurs performances ;
— adopter une stratégie d'évaluation robuste (GroupKFold par `COSMIC_ID`) et des baselines pour éviter les conclusions biaisées.

6.2 Vue globale sur les résultats obtenus

Le notebook fournit une évaluation comparative de plusieurs modèles (linéaires régularisés et ensembles d'arbres) dans un cadre de validation croisée groupée par lignée.

Les résultats se matérialisent par :

— un **dataset nettoyé** exporté au format CSV ;
— un **tableau de benchmark** des modèles avec RMSE/MAE/R^2 (moyenne et écart-type) ;
— un **tableau de baselines** permettant d'évaluer le gain réel par rapport à une prédiction naïve.

Même sans détailler ici des valeurs chiffrées (dépendantes de l'exécution), la méthodologie assure que les scores rapportés sont interprétables et comparables, et qu'ils reflètent une généralisation sur des lignées non vues.

6.3 Impact du projet dans le contexte étudié

La prédiction de la réponse aux traitements est un enjeu central de la médecine de précision. Dans un contexte de recherche préclinique, un modèle prédictif bien évalué peut :

- aider à prioriser des couples (médicament, contexte tumoral) à tester en laboratoire ;
- suggérer des pistes de repositionnement (médicaments efficaces dans des contextes inattendus) ;
- contribuer à identifier des associations entre voies biologiques et sensibilité aux traitements.

Le principal apport de ce travail est d'avoir construit un pipeline reproductible et méthodologiquement prudent (groupement par lignée, baselines), ce qui constitue une base solide pour des extensions vers des données plus riches (omiques) et des usages plus proches du clinique.

6.4 Impact sur votre formation et carrière

Ce projet a renforcé des compétences techniques et méthodologiques utiles en data science appliquée à la bio-informatique :

- préparation de données hétérogènes (Excel/CSV), contrôle d'intégrité et gestion de valeurs manquantes ;
- mise en place de pipelines scikit-learn reproductibles (prétraitement + modèles) ;
- conception d'une évaluation robuste pour éviter la fuite d'information ;
- lecture critique des performances via des baselines et des analyses exploratoires.

Ces acquis sont directement transférables vers des projets de recherche appliquée, d'ingénierie ML ou d'analytique en santé.

6.5 Perspectives

Les perspectives naturelles, en continuité directe avec le notebook, sont :

- **Enrichissement des données** : intégrer des données omiques (expression génique, mutations, CNV) et/ou des descripteurs de structure chimique des composés.
- **Schémas d'évaluation plus exigeants** : tester un split par médicament (`DRUG_ID`) ou des splits « double » (lignée et médicament) pour évaluer une généralisation plus proche d'un cas réel de découverte de traitements.
- **Explicabilité** : quantifier l'importance des variables (Permutation Importance, SHAP) pour relier les prédictions à des facteurs biologiques interprétables.
- **Déploiement** : sérialiser le meilleur modèle et l'exposer via une API (ex. Spring Boot [**?**]) couplée à une interface de visualisation.

Ces extensions permettraient de passer d'un prototype de modélisation à un outil d'aide à la décision plus complet, tout en maintenant la rigueur méthodologique introduite dans ce travail.

Bibliographie

[1] Yang W, Soares J, Greninger P, et al. *Genomics of Drug Sensitivity in Cancer (GDSC) : a resource for therapeutic biomarker discovery in cancer cells*. Nucleic Acids Research, 2013 ; 41(Database issue) :D955-D961. https://www.cancerrxgene.org/

[2] Wong CC, Cheng KW, Rigas B. *Preclinical predictors of anticancer drug efficacy : critical assessment with emphasis on whether nanomolar potency should be required of candidate agents*. J Pharmacol Exp Ther, 2012 ; 341(3) :572-578.

[3] Brindha GR, Rishiikeshwer BS, Santhi B, et al. *Precise prediction of multiple anticancer drug efficacy using multi target regression and support vector regression analysis*. Computer Methods and Programs in Biomedicine, 2022 ; 224 :107027.

[4] Dong X, Liu H, Tong T, et al. *Personalized prediction of anticancer potential of non-oncology drugs through learning from genome derived molecular pathways*. npj Precision Oncology, 2025 ; 9 :36.

[5] National Center for Biotechnology Information (NCBI). https://www.ncbi.nlm.nih.gov