Royaume du Maroc

Université Hassan II de Casablanca

Faculté des Sciences Ben M'Sick

Département Informatique

Drug Discovery using Machine Learning

Prediction of Drug–Target Interactions

Ce projet exploite l'intelligence artificielle et le machine learning pour prédire les interactions entre des molécules chimiques et des protéines cibles, dans le contexte de la conception de médicaments assistée par l'IA.

Réalisé par	**Hajar Bentaib** **Hanane Ayar**
Filière	Master d'Excellence en Intelligence Artificielle
Établissement	Faculté des Sciences Ben M'Sick – FSBM, Casablanca, Maroc
Année universitaire	2025 – 2026
Date	Juin 2026
Encadrants	Mr. BENLAHMAR EL HABIB MmeGUENDOULOUMAIM

Résumé Exécutif

La découverte de nouveaux médicaments constitue l'un des défis majeurs de la recherche biomédicale moderne. Les méthodes expérimentales traditionnelles nécessitent des ressources importantes en temps, en matériel et en expertise, ce qui limite la vitesse d'identification de nouvelles molécules thérapeutiques. Dans ce contexte, l'intelligence artificielle et le machine learning offrent des solutions prometteuses permettant d'accélérer les phases de sélection et d'évaluation des candidats médicaments.

Ce projet s'inscrit dans le domaine de la Drug Discovery assistée par l'intelligence artificielle et vise à développer un système de prédiction des interactions entre molécules chimiques et protéines cibles. L'objectif principal est d'exploiter des techniques de machine learning afin d'estimer l'activité biologique ou l'affinité de liaison d'une molécule à partir de ses propriétés physico-chimiques.

Pour atteindre cet objectif, deux jeux de données de référence ont été utilisés. Le dataset DAVIS a été exploité pour une tâche de régression visant à prédire la constante de dissociation (Kd) entre des molécules et différentes protéines kinases. Le dataset BACE a été utilisé pour une tâche de classification binaire permettant de déterminer si une molécule possède ou non une activité inhibitrice vis-à-vis de la protéine BACE-1.

Un pipeline complet de traitement des données a été mis en œuvre. Celui-ci comprend l'analyse exploratoire, la validation des structures moléculaires, la génération de descripteurs physico-chimiques avec RDKit, la standardisation des variables, la gestion du déséquilibre de classes à l'aide de SMOTE ainsi que la préparation des jeux d'entraînement et de test.

Quatre algorithmes d'apprentissage supervisé ont ensuite été comparés : la Régression Logistique, les Machines à Vecteurs de Support (SVM), les Random Forests et le Gradient Boosting. Les performances ont été évaluées à l'aide de métriques adaptées à chaque tâche. Pour la classification, les métriques Accuracy, Precision, Recall, F1-Score et ROC AUC ont été utilisées. Pour la régression, l'évaluation repose sur les indicateurs MSE, RMSE, MAE et R^2.

Les résultats obtenus montrent que les méthodes ensemblistes offrent les meilleures performances sur les deux jeux de données. Le modèle Gradient Boosting Classifier atteint un score ROC AUC de 0,851 sur le dataset BACE, tandis que le Gradient Boosting Regressor obtient un coefficient de détermination R^2 de 0,395 sur le dataset DAVIS. Ces résultats

confirment la capacité des modèles non linéaires à capturer les relations complexes existant entre les caractéristiques moléculaires et les propriétés biologiques étudiées.
Enfin, ce travail met en évidence l'intérêt du machine learning comme outil d'aide à la décision dans le processus de découverte de médicaments. Il constitue également une base solide pour l'intégration future de techniques plus avancées telles que les représentations moléculaires par graphes, les réseaux de neurones profonds ou les modèles spécialisés de prédiction Drug-Target Interaction.

Table des Matières

Résumé Exécutif 2

Table des Matières 4

Introduction Générale 7

Chapitre 1 : Contexte Scientifique et État de l'Art 9

1.1 Introduction 9

1.2 Processus Général de Drug Discovery 9

1.3 Les Interactions Médicament–Protéine 10

1.4 La Constante de Dissociation (Kd) 10

1.5 Représentation des Molécules Chimiques 11

1.6 Descripteurs Moléculaires 11

1.7 Intelligence Artificielle et Drug Discovery 12

1.8 Machine Learning pour la Prédiction DTI 12

1.9 Travaux Similaires 13

1.10 Conclusion 14

Chapitre 2 : Problématique et Questions de Recherche 15

2.1 Contexte du Problème 15

2.2 Formulation de la Problématique 15

2.3 Questions de Recherche 16

2.4 Hypothèses de Recherche 17

2.5 Approche Proposée 17

2.6 Conclusion 18

Chapitre 3 : Objectifs du Projet 19

3.1 Introduction 19

3.2 Objectif Général 19

3.3 Objectifs Spécifiques 19

3.4 Conclusion 20

Chapitre 4 : Présentation des Données....21
4.1 Introduction....21
4.2 Présentation du Dataset DAVIS....21
4.3 Présentation du Dataset BACE....22
4.4 Comparaison des Deux Datasets....24
4.5 Justification du Choix des Données....24
4.6 Conclusion....25
Chapitre 5 : Prétraitement et Feature Engineering....26
5.1 Introduction....26
5.2 Chargement et Analyse Exploratoire Initiale....26
5.3 Détection et Traitement des Valeurs Manquantes....28
5.4 Détection et Gestion des Doublons....29
5.5 Validation et Canonicalisation des SMILES avec RDKit....29
5.6 Génération des Descripteurs Moléculaires....30
5.7 Analyse Statistique et Visualisation des Features....31
5.8 Traitement des Outliers....32
5.9 Standardisation, Encodage et SMOTE....33
....34
5.10 Réduction de Dimensionnalité PCA....35
5.14 Conclusion....35
Chapitre 6 : Modélisation et Expérimentations....36
6.1 Introduction....36
6.1 Architecture du Pipeline de Modélisation....36
6.2 Modèles de Classification pour BACE....36
6.2.1 Objectif de la tâche....36
6.2.2 Sélection des Variables....37
6.2.3 Division Train/Test....37

6.2.4 Gestion du Déséquilibre avec SMOTE : 37
6.2.5 Modèles Sélectionnés et Justification 38
6.2.6 Résultats de Classification 38
6.2.7 Analyse des Courbes ROC 39
6.2.8 Analyse des Matrices de Confusion 40
6.3 Modèles de Régression pour DAVIS 40
6.3.1 Approche et Features 40
5.3.2 Résultats de Régression 40
6.3.3 Analyse des Graphiques Prédit vs Réel 41
6.3.4 Comparaison Comparative R^2 et RMSE 42
6.4 Conclusion 42
Chapitre 7 : Interface de Prédiction 43
7.1 Introduction et Choix Technologiques 43
7.2 Structure Générale et Navigation 43
7.3 Module 1 : Classification de l'Activité Biologique (BACE-1) 44
7.4 Module 2 : Prédiction d'Affinité de Liaison (DAVIS) 45
7.5 Module 3 : Exploration des Données et Statistiques 47
7.6 Conclusion 47
Conclusion Générale 48
Références Bibliographiques 50
Annexes 50
Annexe A : Extrait du Code de Prétraitement 50
Annexe B : Extrait du Code de Modélisation 51
Annexe C : Glossaire 51

Introduction Générale

Au cours des dernières décennies, le secteur pharmaceutique a connu une croissance considérable grâce aux avancées de la biologie moléculaire, de la génétique et des technologies de calcul. Malgré ces progrès, la découverte de nouveaux médicaments demeure un processus particulièrement long, coûteux et complexe. Selon plusieurs études de l'industrie pharmaceutique, le développement complet d'un médicament, depuis l'identification d'une cible thérapeutique jusqu'à sa commercialisation, peut nécessiter plus de dix années de recherche et représenter plusieurs milliards de dollars d'investissement.

L'une des étapes les plus critiques de ce processus consiste à identifier des molécules capables d'interagir efficacement avec une protéine cible impliquée dans une pathologie donnée. Cette interaction constitue souvent le point de départ du développement d'un traitement thérapeutique. Cependant, l'espace chimique potentiel est gigantesque et contient un nombre pratiquement infini de molécules pouvant être synthétisées. Tester expérimentalement chacune de ces molécules en laboratoire est irréaliste, ce qui rend indispensable le développement de méthodes permettant de sélectionner les candidats les plus prometteurs avant les phases expérimentales.

Dans ce contexte, l'intelligence artificielle et plus particulièrement le Machine Learning se sont imposés comme des outils majeurs pour accélérer la découverte de médicaments. Grâce à leur capacité à apprendre à partir de grandes quantités de données biologiques et chimiques, les algorithmes d'apprentissage automatique permettent aujourd'hui de prédire certaines propriétés moléculaires, d'évaluer l'activité biologique potentielle d'un composé et d'estimer son affinité de liaison avec une protéine cible. Ces approches contribuent à réduire considérablement le nombre d'expériences nécessaires tout en améliorant l'efficacité du processus de recherche pharmaceutique.

Le domaine de la Drug Discovery assistée par l'intelligence artificielle s'inscrit dans une approche multidisciplinaire combinant la bioinformatique, la chimie computationnelle, la science des données et l'apprentissage automatique. Parmi les problématiques les plus étudiées figure la prédiction des interactions médicament–protéine, également appelée Drug-Target Interaction (DTI). Cette tâche consiste à déterminer si une molécule est susceptible d'interagir avec une protéine donnée et à quantifier éventuellement l'intensité de cette interaction.

Dans le cadre de ce projet, nous proposons de développer un pipeline complet de Machine Learning dédié à la prédiction d'interactions médicament–protéine. Deux jeux de données de

référence ont été utilisés afin d'étudier deux problématiques complémentaires. Le dataset DAVIS est exploité pour une tâche de régression visant à prédire l'affinité de liaison entre plusieurs molécules et plusieurs protéines kinases à travers la constante de dissociation Kd. Le dataset BACE est utilisé pour une tâche de classification binaire permettant de déterminer si une molécule possède ou non une activité inhibitrice vis-à-vis de la protéine BACE-1, impliquée dans la maladie d'Alzheimer.

La réalisation de ce projet repose sur plusieurs étapes fondamentales. Une première phase est consacrée à l'analyse et au prétraitement des données, incluant la validation des structures chimiques, la génération de descripteurs moléculaires à l'aide de la bibliothèque RDKit, la gestion des valeurs aberrantes ainsi que la préparation des variables destinées aux algorithmes d'apprentissage. Une seconde phase concerne l'entraînement et l'évaluation de différents modèles supervisés tels que la Régression Logistique, les Machines à Vecteurs de Support (SVM), les Random Forests et le Gradient Boosting. Enfin, les performances obtenues sont analysées à travers plusieurs métriques quantitatives et visualisations afin d'identifier les approches les plus adaptées à chaque tâche.

L'objectif principal de ce travail est d'étudier la capacité des méthodes de Machine Learning à prédire efficacement des interactions biologiques complexes à partir de données moléculaires réelles. Au-delà de l'aspect applicatif, ce projet constitue également une occasion d'explorer l'ensemble du cycle de vie d'un projet de Data Science appliqué à un domaine scientifique à fort impact sociétal.

Le présent rapport est organisé en sept chapitres. Le premier chapitre présente la problématique scientifique ainsi que les questions de recherche abordées. Le deuxième chapitre détaille les objectifs du projet. Le troisième chapitre décrit les jeux de données utilisés. Le quatrième chapitre est consacré au prétraitement et à l'ingénierie des caractéristiques. Le cinquième chapitre présente les modèles de Machine Learning mis en œuvre ainsi que les expérimentations réalisées. Le sixième chapitre analyse les résultats obtenus et discute leurs implications. Enfin, le septième chapitre présente l'interface de prédiction développée avant de conclure sur les perspectives futures du projet.

Chapitre 1 : Contexte Scientifique et État de l'Art

1.1 Introduction

La découverte de médicaments (Drug Discovery) constitue l'un des domaines les plus importants de la recherche biomédicale moderne. Son objectif principal est d'identifier des molécules capables d'agir sur des cibles biologiques spécifiques afin de prévenir, traiter ou guérir certaines maladies.

Traditionnellement, ce processus repose sur des expérimentations biologiques et chimiques réalisées en laboratoire. Les chercheurs doivent tester un très grand nombre de molécules afin d'identifier celles qui présentent une activité thérapeutique potentielle. Cette approche expérimentale est particulièrement coûteuse, longue et nécessite des ressources importantes.

Avec l'apparition de l'intelligence artificielle et du machine learning, de nouvelles approches computationnelles ont émergé afin d'accélérer ce processus. Ces méthodes permettent d'exploiter les données biologiques existantes pour prédire automatiquement certaines propriétés des molécules avant leur validation expérimentale.

1.2 Processus Général de Drug Discovery

Le développement d'un médicament suit généralement plusieurs étapes successives.

Identification de la cible thérapeutique

La première étape consiste à identifier une protéine ou un mécanisme biologique impliqué dans une maladie donnée.

Une cible thérapeutique peut être :

- une enzyme
- un récepteur
- un canal ionique
- une protéine impliquée dans une voie métabolique.

L'objectif est de trouver une molécule capable d'interagir avec cette cible afin de modifier son activité biologique.

Identification des molécules candidates

Une fois la cible identifiée, les chercheurs recherchent des molécules susceptibles de produire l'effet souhaité.

Cette phase est appelée :

Screening ou Criblage Moléculaire

Elle peut impliquer des milliers voire des millions de molécules différentes.

Optimisation des candidats

Les molécules les plus prometteuses sont ensuite modifiées chimiquement afin d'améliorer :

- leur efficacité
- leur sélectivité
- leur stabilité
- leur toxicité

Essais précliniques et cliniques

Les molécules sélectionnées passent ensuite par plusieurs phases d'évaluation :

- Tests in vitro ;
- Tests sur animaux ;
- Essais cliniques chez l'homme.

La majorité des molécules échouent durant ces étapes.

1.3 Les Interactions Médicament–Protéine

Une interaction médicament–protéine correspond à la capacité d'une molécule à se lier à une protéine cible.

Cette interaction est à l'origine de l'effet thérapeutique recherché.

Par exemple :

- L'aspirine agit sur l'enzyme COX.
- Les inhibiteurs de kinases agissent sur certaines protéines impliquées dans le cancer.
- Les inhibiteurs BACE-1 sont étudiés dans le traitement de la maladie d'Alzheimer.

La qualité de cette interaction peut être mesurée par différentes grandeurs biologiques.

Parmi les plus importantes :

- IC50 ;
- EC50 ;
- Ki ;
- Kd.

Dans le cadre du dataset DAVIS, la mesure utilisée est la constante de dissociation Kd.

1.4 La Constante de Dissociation (Kd)

La constante de dissociation Kd représente la force de liaison entre une molécule et une protéine.

Plus la valeur de Kd est faible :

→ plus la liaison est forte.

Plus la valeur de Kd est élevée :

→ plus la liaison est faible.

Cette mesure est largement utilisée en pharmacologie afin d'évaluer l'efficacité potentielle d'un candidat médicament.

La prédiction de Kd constitue donc un problème de régression particulièrement important dans la Drug Discovery moderne.

1.5 Représentation des Molécules Chimiques

Les molécules ne peuvent pas être directement utilisées par les algorithmes de machine learning.

Elles doivent être converties sous une forme numérique.

Notation SMILES

La représentation la plus utilisée est le format SMILES (Simplified Molecular Input Line Entry System).

Exemple :

- Molécule d'éthanol : CCO
- Molécule de benzène : c1ccccc1

Le format SMILES permet de représenter une structure chimique sous forme de texte.

Cette représentation est compacte, facile à stocker et largement utilisée dans les bases de données chimiques.

1.6 Descripteurs Moléculaires

Descripteur	Description
Molecular Weight	Masse moléculaire
LogP	Lipophilie
TPSA	Surface polaire topologique
NumHDonors	Donneurs de liaison hydrogène
NumHAcceptors	Accepteurs de liaison hydrogène

Rotatable Bonds	Flexibilité moléculaire
Ring Count	Nombre de cycles
Heavy Atom Count	Nombre d'atomes lourds

Afin d'utiliser les molécules dans des modèles de machine learning classiques, il est nécessaire d'extraire des caractéristiques numériques appelées descripteurs moléculaires. Ces descripteurs résument certaines propriétés chimiques et biologiques.
Dans ce projet, huit descripteurs ont été utilisés :
Ces variables constituent les principales entrées des modèles de machine learning.

1.7 Intelligence Artificielle et Drug Discovery

L'utilisation de l'intelligence artificielle dans la découverte de médicaments connaît une croissance rapide depuis plusieurs années.
Les principaux avantages sont :

- Réduction du coût de recherche.
- Réduction du temps de développement.
- Exploration d'un espace chimique immense.
- Priorisation automatique des molécules prometteuses.
- Amélioration de la prise de décision scientifique.

Aujourd'hui, de nombreuses entreprises pharmaceutiques utilisent des modèles d'apprentissage automatique dans leurs pipelines de recherche.
Parmi elles :

- DeepMind ;
- Insilico Medicine ;
- BenevolentAI ;
- Exscientia.

Ces entreprises démontrent le potentiel de l'IA pour accélérer la découverte de nouvelles thérapies.

1.8 Machine Learning pour la Prédiction DTI

La prédiction des interactions médicament–protéine (Drug Target Interaction Prediction) est devenue un problème classique du machine learning.

Les approches utilisées peuvent être regroupées en trois catégories.

Approches Traditionnelles

Elles reposent sur des modèles statistiques simples :

- Régression Logistique ;
- Régression Linéaire ;
- Naive Bayes.

Ces modèles sont faciles à interpréter mais limités face aux relations non linéaires.

Méthodes Ensemblistes

Ces méthodes combinent plusieurs arbres de décision :

- Random Forest ;
- Gradient Boosting ;
- XGBoost ;
- LightGBM.

Elles offrent généralement de meilleures performances sur les données tabulaires.

Deep Learning

Les approches récentes utilisent :

- Réseaux de neurones profonds ;
- Convolutional Neural Networks (CNN) ;
- Graph Neural Networks (GNN) ;
- Transformers biologiques.

Ces modèles représentent actuellement l'état de l'art dans plusieurs tâches de Drug Discovery.

1.9 Travaux Similaires

Plusieurs études ont démontré l'efficacité du machine learning pour la prédiction d'interactions médicament–protéine.

Les benchmarks MoleculeNet montrent régulièrement la supériorité des modèles ensemblistes sur les approches linéaires.

Des architectures spécialisées comme DeepDTA, GraphDTA et AttentionDTA ont permis d'obtenir des performances encore plus élevées grâce à l'utilisation simultanée des structures moléculaires et des séquences protéiques.

Ces travaux constituent la base scientifique ayant inspiré la méthodologie adoptée dans ce projet.

1.10 Conclusion

La Drug Discovery représente aujourd'hui un domaine stratégique où l'intelligence artificielle joue un rôle de plus en plus important. Les interactions médicament–protéine constituent le cœur du développement thérapeutique moderne et leur prédiction automatique permet d'accélérer considérablement la recherche pharmaceutique.
L'utilisation des datasets DAVIS et BACE offre un cadre expérimental pertinent pour étudier à la fois la prédiction quantitative d'affinité de liaison et la classification d'activité moléculaire. Les concepts présentés dans ce chapitre fournissent les bases théoriques nécessaires à la compréhension de la méthodologie développée dans les chapitres suivants.

Chapitre 2 : Problématique et Questions de Recherche

2.1 Contexte du Problème

La découverte de nouvelles molécules thérapeutiques représente un défi scientifique majeur dans le domaine biomédical. Malgré les progrès réalisés en biologie moléculaire et en chimie pharmaceutique, le développement d'un nouveau médicament reste un processus particulièrement long et coûteux. En moyenne, plusieurs années de recherche sont nécessaires avant qu'une molécule puisse atteindre les phases cliniques, avec un taux d'échec très élevé.
L'une des étapes les plus critiques consiste à identifier des molécules capables d'interagir efficacement avec une protéine cible impliquée dans une maladie donnée. Cette interaction constitue souvent la base de l'effet thérapeutique recherché.
Dans un contexte réel, les chercheurs disposent de millions de molécules potentiellement exploitables. Tester expérimentalement chacune de ces molécules est impossible en raison des contraintes de temps, de coût et de ressources matérielles. Il devient donc nécessaire de développer des méthodes capables d'orienter les expérimentations vers les candidats les plus prometteurs.
Les méthodes de Machine Learning apparaissent aujourd'hui comme une solution particulièrement pertinente. En apprenant à partir de données biologiques et chimiques déjà connues, ces modèles peuvent prédire le comportement de nouvelles molécules avant leur validation expérimentale.
Cependant, la mise en œuvre de tels systèmes soulève plusieurs défis importants liés à la nature des données biologiques, à la représentation des molécules et des protéines ainsi qu'au choix des algorithmes de prédiction.

2.2 Formulation de la Problématique

Le problème central étudié dans ce projet peut être formulé de la manière suivante :

> Comment exploiter les techniques de Machine Learning afin de prédire efficacement les interactions entre molécules chimiques et protéines cibles à partir de données biologiques réelles, dans le but d'assister le processus de découverte de médicaments ?

Cette problématique se situe à l'intersection de plusieurs disciplines :

- Intelligence Artificielle ;
- Machine Learning ;
- Bioinformatique ;
- Chimie Computationnelle ;
- Science des Données.

Elle vise à déterminer dans quelle mesure des modèles prédictifs peuvent reproduire les résultats obtenus expérimentalement et ainsi réduire le nombre d'expériences nécessaires lors des phases de recherche pharmaceutique.

2.3 Questions de Recherche

Afin de répondre à cette problématique générale, plusieurs questions scientifiques sont étudiées.

Question 1

Comment transformer une représentation moléculaire sous forme de chaîne SMILES en variables numériques exploitables par des algorithmes de Machine Learning ?

Question 2

Les descripteurs physico-chimiques calculés à partir des molécules sont-ils suffisamment informatifs pour prédire l'activité biologique ou l'affinité de liaison ?

Question 3

Quels modèles de Machine Learning offrent les meilleures performances pour les tâches de classification moléculaire et de prédiction d'affinité médicament-protéine ?

Question 4

Les modèles non linéaires permettent-ils de mieux capturer la complexité des interactions biologiques que les approches linéaires traditionnelles ?

Question 5

Comment évaluer objectivement la qualité des prédictions obtenues à l'aide de métriques adaptées aux tâches de classification et de régression ?

Question 6

Dans quelle mesure les résultats obtenus peuvent-ils être utilisés comme outil d'aide à la décision dans un contexte réel de Drug Discovery ?

2.4 Hypothèses de Recherche

Le projet repose sur plusieurs hypothèses scientifiques qui guideront les expérimentations.

H1 : Pertinence des descripteurs moléculaires

Les propriétés physico-chimiques calculées à partir des molécules contiennent suffisamment d'informations pour permettre aux modèles de différencier des molécules actives de molécules inactives et d'estimer leur affinité de liaison.

H2 : Supériorité des modèles non linéaires

Les modèles ensemblistes tels que Random Forest et Gradient Boosting devraient obtenir de meilleures performances que les modèles linéaires grâce à leur capacité à capturer des relations complexes entre les variables.

H3 : Impact du prétraitement

La validation des molécules, la standardisation des données et le traitement du déséquilibre de classes devraient améliorer la qualité des prédictions finales.

H4 : Faisabilité de la prédiction DTI

Il est possible d'obtenir des performances suffisamment satisfaisantes pour démontrer l'intérêt du Machine Learning comme outil d'assistance à la découverte de médicaments.

2.5 Approche Proposée

Pour répondre à ces questions de recherche, nous proposons une approche basée sur un pipeline complet de Machine Learning appliqué à deux jeux de données complémentaires.
Le dataset BACE est utilisé pour étudier un problème de classification binaire consistant à prédire si une molécule possède une activité inhibitrice vis-à-vis de la protéine BACE-1.
Le dataset DAVIS est utilisé pour étudier un problème de régression visant à prédire quantitativement la force de liaison entre une molécule et différentes protéines kinases à travers la constante de dissociation Kd.
L'approche proposée comprend :

1. L'analyse exploratoire des données.
2. Le prétraitement et la validation des structures moléculaires.
3. La génération de descripteurs physico-chimiques avec RDKit.
4. La préparation des variables d'apprentissage.
5. L'entraînement de plusieurs modèles supervisés.
6. La comparaison des performances obtenues.

7. L'interprétation scientifique des résultats.

Cette méthodologie permettra d'évaluer la pertinence des approches classiques de Machine Learning dans un contexte de Drug Discovery appliqué à des données réelles.

2.6 Conclusion

Ce chapitre a présenté la problématique scientifique étudiée ainsi que les principales questions de recherche auxquelles ce projet tente de répondre. Les défis liés à la prédiction des interactions médicament-protéine justifient l'utilisation d'approches basées sur le Machine Learning afin d'accélérer le processus de découverte de médicaments.
Les hypothèses formulées serviront de fil conducteur pour l'ensemble des expérimentations présentées dans les chapitres suivants. Le chapitre suivant sera consacré à la définition détaillée des objectifs du projet ainsi qu'à la présentation des jeux de données utilisés.

Chapitre 3 : Objectifs du Projet

3.1 Introduction

Dans le contexte de la découverte assistée de médicaments, l'utilisation du Machine Learning offre de nouvelles possibilités pour prédire les interactions entre molécules chimiques et protéines cibles. Ce projet vise à mettre en œuvre une approche basée sur l'intelligence artificielle afin d'étudier la faisabilité de telles prédictions à partir de données biologiques réelles.

3.2 Objectif Général

L'objectif principal de ce projet est de développer un pipeline complet de Machine Learning permettant de prédire l'activité biologique de molécules ainsi que leur affinité de liaison avec des protéines cibles. À travers cette démarche, nous cherchons à évaluer l'efficacité des techniques d'apprentissage supervisé dans le domaine de la Drug Discovery et à identifier les modèles les plus performants pour ce type de problématique.

3.3 Objectifs Spécifiques

Pour atteindre cet objectif général, plusieurs objectifs spécifiques ont été définis :

- Étudier et comprendre la structure des datasets DAVIS et BACE utilisés dans le domaine de la bioinformatique.
- Réaliser une analyse exploratoire afin d'évaluer la qualité des données et d'identifier d'éventuelles anomalies.
- Construire un pipeline de prétraitement incluant la validation des molécules, la génération de descripteurs moléculaires et la préparation des variables d'apprentissage.
- Transformer les représentations chimiques sous forme de SMILES en caractéristiques numériques exploitables grâce à la bibliothèque RDKit.
- Entraîner plusieurs modèles de Machine Learning pour des tâches de classification et de régression.
- Comparer les performances des modèles à l'aide de métriques adaptées telles que Accuracy, F1-Score, ROC AUC, RMSE et R^2.
- Interpréter les résultats obtenus et identifier les approches les plus pertinentes pour la prédiction des interactions médicament–protéine.

- Développer une interface simple permettant d'effectuer des prédictions à partir de nouvelles molécules.

3.4 Conclusion

Les objectifs définis dans ce chapitre constituent le cadre méthodologique du projet. Ils orientent les différentes étapes de collecte, de traitement, de modélisation et d'évaluation présentées dans la suite du rapport. Le chapitre suivant est consacré à la présentation détaillée des jeux de données DAVIS et BACE utilisés pour les expérimentations.

Chapitre 4 : Présentation des Données

4.1 Introduction

Les performances d'un système de Machine Learning dépendent fortement de la qualité et de la pertinence des données utilisées lors de l'apprentissage. Avant toute phase de prétraitement ou de modélisation, il est donc nécessaire de comprendre la structure des données, leur origine, leurs caractéristiques ainsi que leur adéquation avec la problématique étudiée.
Dans le cadre de ce projet, deux jeux de données de référence ont été sélectionnés : **DAVIS** et **BACE**. Ces datasets sont largement utilisés dans la littérature scientifique en Drug Discovery et en bioinformatique pour l'évaluation des modèles de prédiction d'interactions médicament–protéine.
Le dataset DAVIS constitue la base principale du projet puisqu'il permet de prédire l'affinité de liaison entre plusieurs molécules et plusieurs protéines cibles. Le dataset BACE est utilisé comme benchmark complémentaire pour une tâche de classification moléculaire binaire.

4.2 Présentation du Dataset DAVIS

Le dataset DAVIS est l'un des jeux de données les plus utilisés dans le domaine de la prédiction des interactions médicament–protéine (Drug-Target Interaction Prediction).
Il a été construit à partir d'expériences biologiques réelles visant à mesurer l'affinité de liaison entre différentes molécules chimiques et un ensemble de protéines kinases humaines.
Chaque ligne du dataset représente une interaction entre une molécule et une protéine spécifique.

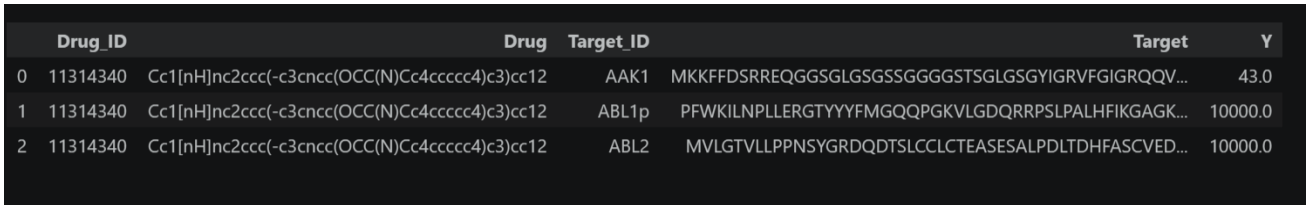
Structure du Dataset DAVIS :

Variable	Description
Drug_ID	Identifiant unique de la molécule
Drug	Structure chimique au format SMILES
Target_ID	Identifiant de la protéine
Target	Séquence d'acides aminés de la protéine
Y	Valeur de l'affinité de liaison (Kd en nM)

Statistiques du Dataset DAVIS :

Caractéristique	Valeur
Nombre de molécules uniques	68
Nombre de protéines uniques	379
Nombre total d'interactions	25 772
Variable cible	Y
Type de problème	Régression

La variable cible **Y** correspond à la constante de dissociation (Kd), qui mesure la force de liaison entre une molécule et une protéine.
Plus la valeur de Kd est faible, plus l'interaction entre la molécule et la protéine est forte.



	Drug_ID	Drug	Target_ID	Target	Y
0	11314340	Cc1[nH]nc2ccc(-c3cncc(OCC(N)Cc4ccccc4)c3)cc12	AAK1	MKKFFDSRREQGGSGLGSGSSGGGGSTSGLGSGYIGRVFGIGRQQV...	43.0
1	11314340	Cc1[nH]nc2ccc(-c3cncc(OCC(N)Cc4ccccc4)c3)cc12	ABL1p	PFWKILNPLLERGTYYYFMGQQPGKVLGDQRRPSLPALHFIKGAGK...	10000.0
2	11314340	Cc1[nH]nc2ccc(-c3cncc(OCC(N)Cc4ccccc4)c3)cc12	ABL2	MVLGTVLLPPNSYGRDQDTSLCCLCTEASESALPDLTDHFASCVED...	10000.0

Figure 1:Aperçu DAVIS

Importance du Dataset DAVIS

Le principal intérêt de DAVIS réside dans son caractère multi-cible. Contrairement à de nombreux jeux de données limités à une seule protéine, DAVIS permet d'étudier simultanément plusieurs protéines et plusieurs molécules.
Cette caractéristique rapproche davantage le projet d'un contexte réel de recherche pharmaceutique où une molécule peut interagir avec différentes protéines biologiques.

4.3 Présentation du Dataset BACE

Le dataset BACE est un benchmark de référence dans le domaine de la découverte de médicaments.
Il est consacré à l'étude de la protéine **BACE-1 (Beta-Secretase 1)**, une cible thérapeutique importante impliquée dans le développement de la maladie d'Alzheimer.
L'objectif consiste à déterminer si une molécule possède ou non une activité inhibitrice vis-à-vis de cette protéine.
Contrairement au dataset DAVIS, il s'agit ici d'un problème de classification binaire.

Structure du Dataset BACE :

Variable	Description
mol	Molécule au format SMILES
Class	Activité biologique de la molécule
Descripteurs	Variables physico-chimiques calculées

Variable cible :

Valeur	Signification
1	Molécule active
0	Molécule inactive

Statistiques du Dataset BACE :

Caractéristique	Valeur
Nombre de molécules	1 513
Nombre de colonnes	Plus de 600
Variable cible	Class
Type de problème	Classification binaire

	mol	CID	Class	Model	pIC50	MW	AlogP	HBA	HBD	RB	...	PEOE6 (PEOE6)
0	O1CC[C@@H](NC(=O)[C@@H](Cc2cc3cc(ccc3nc2N)-c2c...	BACE_1	1	Train	9.154901	431.56979	4.4014	3	2	5	...	53.205711
1	Fc1cc(cc(F)c1)C[C@H](NC(=O)[C@@H](N1CC[C@](NC(...	BACE_2	1	Train	8.853872	657.81073	2.6412	5	4	16	...	73.817162
2	S1(=O)(=O)N(c2cc(cc3c2n(cc3CC)CC1)C(=O)N[C@H](...	BACE_3	1	Train	8.698970	591.74091	2.5499	4	3	11	...	70.365707

Figure 2:Aperçu BACE

PEOE7 (PEOE7)	PEOE8 (PEOE8)	PEOE9 (PEOE9)	PEOE10 (PEOE10)	PEOE11 (PEOE11)	PEOE12 (PEOE12)	PEOE13 (PEOE13)	PEOE14 (PEOE14)	canvasUID
78.640335	226.85541	107.43491	37.133846	0.000000	7.980170	0.0	0.000000	1
47.171600	365.67694	174.07675	34.923889	7.980170	24.148668	0.0	24.663788	2
47.941147	192.40652	255.75255	23.654478	0.230159	15.879790	0.0	24.663788	3

Importance du Dataset BACE

Le dataset BACE est largement utilisé dans les benchmarks de Drug Discovery et figure notamment dans la plateforme MoleculeNet.
Il constitue un excellent cas d'étude pour évaluer la capacité des modèles de Machine Learning à distinguer les molécules actives des molécules inactives.

4.4 Comparaison des Deux Datasets

Les datasets DAVIS et BACE présentent des caractéristiques complémentaires qui permettent d'évaluer différentes approches de Machine Learning.

Critère	DAVIS	BACE
Domaine	Interaction médicament-protéine	Activité moléculaire
Type de tâche	Régression	Classification
Nombre de molécules	68	1513
Nombre de protéines	379	1
Variable cible	Kd	Classe active/inactive
Complexité	Élevée	Modérée

Le dataset DAVIS permet d'étudier un scénario réaliste impliquant plusieurs protéines cibles, tandis que BACE permet de valider les méthodes de classification sur une tâche plus simple et mieux contrôlée.
L'utilisation conjointe de ces deux datasets permet ainsi d'évaluer la robustesse des modèles dans deux contextes différents de Drug Discovery.

4.5 Justification du Choix des Données

Le choix des datasets DAVIS et BACE repose sur plusieurs motivations scientifiques.
Premièrement, ces jeux de données sont largement reconnus et utilisés dans la littérature spécialisée en bioinformatique et en intelligence artificielle appliquée à la découverte de médicaments.
Deuxièmement, ils permettent de couvrir deux problématiques complémentaires : la régression pour la prédiction quantitative de l'affinité de liaison et la classification pour la prédiction de l'activité biologique.
Troisièmement, leur utilisation facilite la comparaison des performances obtenues avec celles rapportées dans les travaux scientifiques existants.

Enfin, ces datasets offrent une base solide pour la mise en œuvre d'un pipeline complet de Machine Learning allant du prétraitement des données jusqu'à la prédiction finale.

4.6 Conclusion

Dans ce chapitre, nous avons présenté les deux jeux de données utilisés tout au long du projet. Le dataset DAVIS constitue la source principale d'apprentissage pour la prédiction des interactions médicament–protéine, tandis que le dataset BACE sert de benchmark complémentaire pour la classification moléculaire.
L'analyse de leur structure et de leurs caractéristiques confirme leur pertinence vis-à-vis des objectifs du projet. La prochaine étape consiste à préparer ces données à travers un processus rigoureux de prétraitement, d'extraction de caractéristiques et d'ingénierie des variables avant la phase de modélisation.

Chapitre 5 : Prétraitement et Feature Engineering

5.1 Introduction

La qualité des données constitue un facteur déterminant dans la performance d'un système de Machine Learning. Dans le domaine de la Drug Discovery, les données chimiques et biologiques présentent des caractéristiques particulières nécessitant plusieurs étapes de transformation avant leur exploitation par des algorithmes prédictifs.
L'objectif de cette phase est de convertir les représentations chimiques brutes des molécules en variables numériques pertinentes tout en garantissant la qualité, la cohérence et la robustesse des données utilisées pour l'apprentissage.
Le pipeline de prétraitement développé dans ce projet comprend les étapes suivantes :

- Analyse exploratoire initiale ;
- Vérification des valeurs manquantes ;
- Détection des doublons ;
- Validation chimique des molécules ;
- Canonicalisation des représentations SMILES ;
- Génération des descripteurs moléculaires ;
- Analyse statistique des variables ;
- Détection et traitement des valeurs aberrantes ;
- Standardisation des variables ;
- Gestion du déséquilibre de classes ;
- Réduction de dimensionnalité pour l'analyse exploratoire.

5.2 Chargement et Analyse Exploratoire Initiale

Les bibliothèques Python utilisées pour ce pipeline incluent : pandas et numpy pour la manipulation des données, matplotlib et seaborn pour la visualisation, RDKit pour le traitement chimio-informatique des molécules, scikit-learn pour la modélisation et le prétraitement, et imbalanced-learn (SMOTE) pour la gestion du déséquilibre de classes.

Avant toute transformation, une analyse descriptive des datasets DAVIS et BACE a été réalisée afin de comprendre leur structure générale.

Dataset DAVIS

Le dataset DAVIS contient :

- 25 772 interactions médicament-protéine
- 68 molécules uniques
- 379 protéines uniques

Chaque ligne représente une interaction entre :

- une molécule chimique (Drug)
- une protéine cible (Target)
- une valeur d'affinité de liaison (Y)

Dataset BACE

Le dataset BACE contient :

- 1 513 molécules
- une variable cible binaire Class
- plusieurs descripteurs moléculaires

La variable cible prend les valeurs :

- 1 : molécule active
- 0 : molécule inactive

L'analyse préliminaire permet de vérifier la cohérence générale des données avant toute étape de nettoyage.

	Drug_ID	Drug	Target_ID	Target	Y
count	2.577200e+04	25772	25772	25772	25772.000000
unique	NaN	68	379	379	NaN
top	NaN	Cc1[nH]nc2ccc(-c3cncc(OCC(N)Cc4ccccc4)c3)cc12	ZAP70	MPDPAAHLPFFYGSISRAEAEEHLKLAGMADGLFLLRQCLRSLGGY...	NaN
freq	NaN	379	68	68	NaN
mean	1.037657e+07	NaN	NaN	NaN	7558.112997
std	1.020455e+07	NaN	NaN	NaN	3990.013578
min	5.291000e+03	NaN	NaN	NaN	0.016000
25%	3.038524e+06	NaN	NaN	NaN	3775.000000
50%	1.000406e+07	NaN	NaN	NaN	10000.000000
75%	1.165936e+07	NaN	NaN	NaN	10000.000000
max	5.100435e+07	NaN	NaN	NaN	10000.000000

Figure 3 : Statistiques descriptives DAVIS

	mol	CID	Class	Model	pIC50	MW	AlogP	HBA
count	1513	1513	1513.000000	1513	1513.000000	1513.000000	1513.000000	1513.000000
unique	1513	1513	NaN	3	NaN	NaN	NaN	NaN
top	Clc1cc2nc(n(c2cc1)CCCC(=O)NCC1CC1)N	BACE_1547	NaN	Test	NaN	NaN	NaN	NaN
freq	1	1	NaN	1265	NaN	NaN	NaN	NaN
mean	NaN	NaN	0.456709	NaN	6.521991	479.661988	3.177080	3.732981
std	NaN	NaN	0.498287	NaN	1.342417	122.083053	1.396633	1.444778
min	NaN	NaN	0.000000	NaN	2.544546	138.187000	-4.361100	0.000000
25%	NaN	NaN	0.000000	NaN	5.585027	389.331300	2.335500	3.000000
50%	NaN	NaN	0.000000	NaN	6.761954	463.628300	3.171300	4.000000
75%	NaN	NaN	1.000000	NaN	7.540000	564.639530	4.015500	4.000000
max	NaN	NaN	1.000000	NaN	10.522879	1350.473300	7.617400	12.000000

Figure 4 : Statistiques descriptives BACE (premières colonnes)

5.3 Détection et Traitement des Valeurs Manquantes

La première étape critique consiste à quantifier les valeurs manquantes (NaN) dans chaque dataset. Des heatmaps de présence/absence ont été générées pour visualiser spatialement la répartition des données manquantes. Le résultat de cette analyse est le suivant :

Dataset	Valeurs Manquantes Totales	Décision
BACE	0 (Aucune)	Aucun traitement requis
DAVIS	0 (Aucune)	Aucun traitement requis

Les deux datasets BACE et DAVIS possèdent zéro valeur manquante sur l'ensemble de leurs lignes et colonnes. Par conséquent, aucune procédure de suppression ou d'imputation (par moyenne, médiane, K-NN Imputer ou Iterative Imputer) n'a été nécessaire.

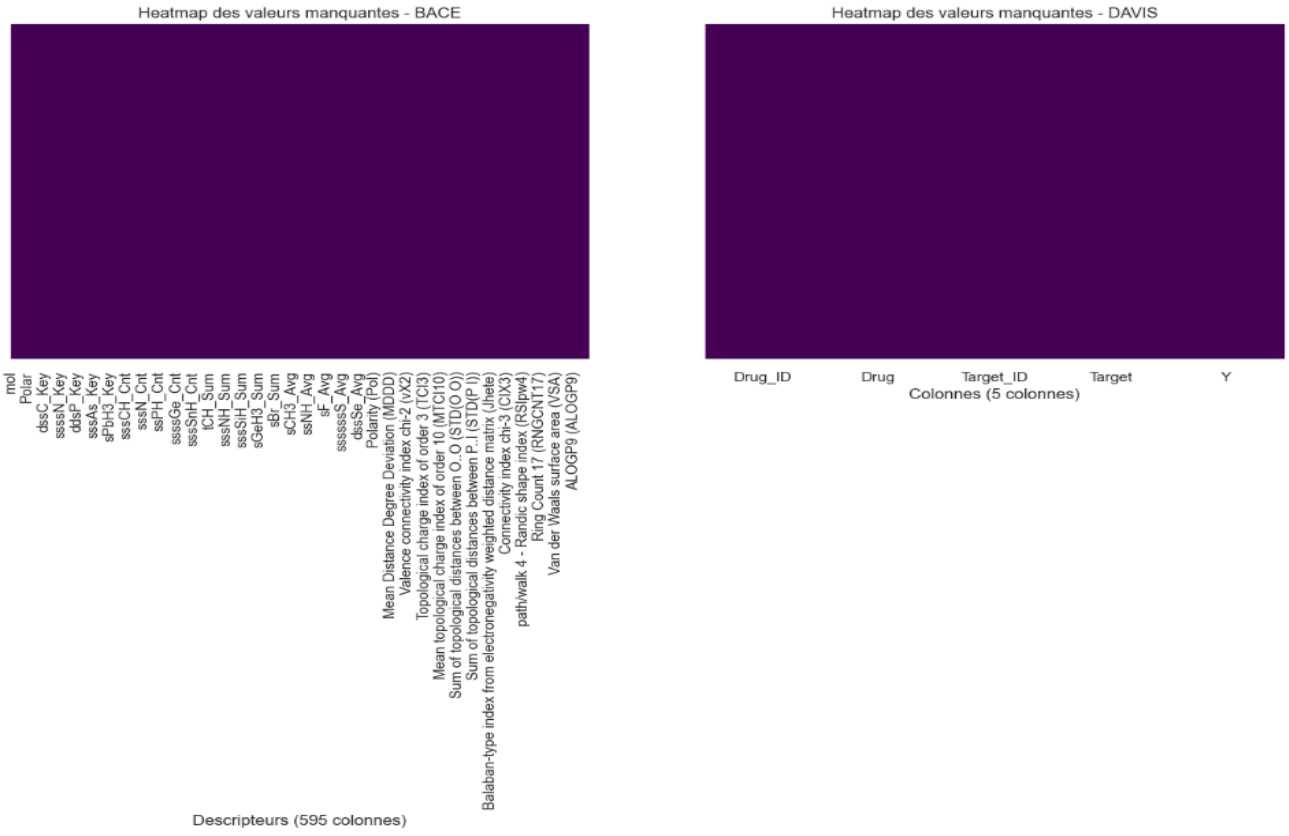


Figure 5:Heatmap des valeurs manquantes

Analyse :

La figure confirme l’absence de données manquantes dans l’ensemble des colonnes.

5.4 Détection et Gestion des Doublons

La présence de doublons peut induire un surapprentissage et fausser l'évaluation finale du modèle. Nous distinguons trois types de doublons dans ce contexte :

- Doublons de lignes complètes (toutes les colonnes identiques)
- Doublons moléculaires (même chaîne SMILES)
- Doublons de paires d'interaction (même couple molécule–protéine, spécifique à DAVIS)

Résultats de l'analyse des doublons :

Dataset	Doublons complets	Doublons SMILES	Doublons paires
BACE	0	0	N/A
DAVIS	0	25 704*	0

Les 25 704 doublons de SMILES dans DAVIS sont fonctionnellement justifiés : chaque drogue est testée contre de multiples protéines cibles différentes. Ces doublons sont indispensables à la tâche d'apprentissage et ne doivent pas être supprimés.

5.5 Validation et Canonicalisation des SMILES avec RDKit

Avant tout calcul chimio-informatique, la validité chimique de chaque molécule doit être vérifiée. La fonction Chem.MolFromSmiles() de RDKit permet de parser et valider chaque chaîne SMILES. Si cette fonction renvoie None, la molécule est jugée invalide et exclue du dataset.

Cette étape permet :

- de détecter les molécules invalides ;
- d’éviter l’introduction d’erreurs chimiques ;
- de garantir la cohérence du calcul des descripteurs.

La canonicalisation des SMILES est une étape essentielle : une même structure chimique peut avoir plusieurs représentations SMILES différentes selon l'ordre de parcours des atomes. La fonction Chem.MolToSmiles(mol, canonical=True) convertit chaque SMILES vers sa représentation normalisée unique, garantissant la cohérence des données.

Cette étape améliore :

- la cohérence des données ;
- la reproductibilité des résultats ;

- l'élimination des représentations redondantes.

Dataset	Molécules initiales	Molécules invalides	Molécules retenues
BACE	1 513	0	1 513 (100%)
DAVIS	30 056	0	30 056 (100%)

5.6 Génération des Descripteurs Moléculaires

Les chaînes SMILES ne peuvent pas servir directement d'entrées pour des modèles de machine learning classiques. Il est nécessaire de les transformer en vecteurs numériques. Nous calculons 8 descripteurs physico-chimiques fondamentaux, inspirés des règles de Lipinski (Rule of Five), qui quantifient les propriétés ADME (Absorption, Distribution, Métabolisme, Excrétion) des molécules.

Descripteur	Symbole RDKit	Signification biologique
Masse Moléculaire	MolWt	Taille de la molécule – doit être < 500 Da (règle de Lipinski)
Lipophilie (LogP)	MolLogP	Solubilité dans les lipides – lié à l'absorption membranaire
Surface Polaire Topologique	TPSA	Indicateur d'absorption intestinale et de passage BHE
Donneurs H-Bond	NumHDonors	Liaisons donneuses d'hydrogène – doit être ≤ 5
Accepteurs H-Bond	NumHAcceptors	Liaisons acceptrices d'hydrogène – doit être ≤ 10
Liaisons Rotatives	NumRotatableBonds	Flexibilité moléculaire – impact sur la biodisponibilité
Nombre de Cycles	RingCount	Rigidité structurelle – systèmes aromatiques
Atomes Lourds	HeavyAtomCount	Taille atomique (non-H) – corrélé à la masse moléculaire

	mol	MW	LogP	TPSA	NumHDonors	NumHAcceptors	RotatableBonds	RingCount	HeavyAtomCount
0	Cc1ccccc1-c1ccc2nc(N)c(C[C@@H](C)C(=O)N[C@@H]3...	431.580	5.04482	77.24	2	4	5	4	32
1	CCCO[C@H]1C[NH2+][C@@H]([C@@H](O)[C@H](Cc2cc(F...	657.823	2.63860	124.58	4	5	16	4	47
2	CCc1cn2c3c(cc(C(=O)N[C@@H](Cc4ccccc4)[C@H](O)C...	591.754	2.45750	117.48	3	5	11	5	42

Figure 6: Aperçu des caractéristiques moléculaires dans BACE

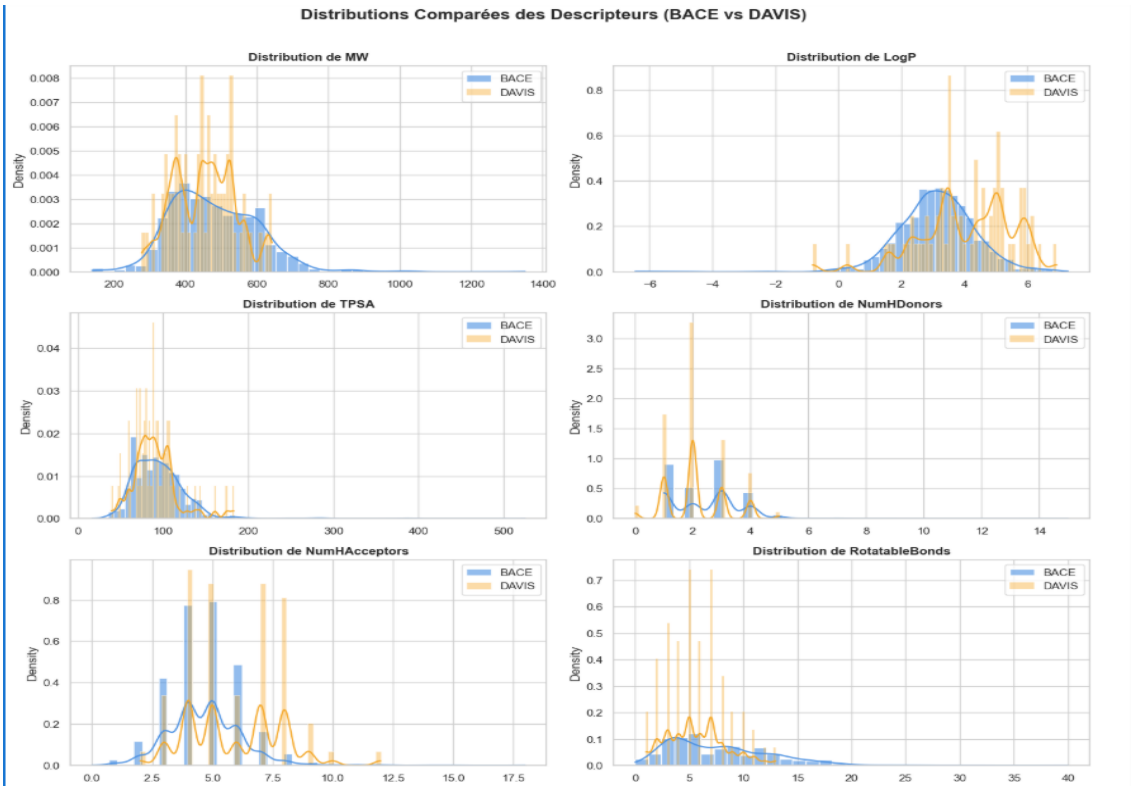
Analyse :

Cette étape transforme chaque molécule en un ensemble de caractéristiques numériques exploitables par les modèles prédictifs.

5.7 Analyse Statistique et Visualisation des Features

Une analyse exploratoire approfondie des 8 descripteurs a été réalisée pour les deux datasets. Plusieurs types de visualisations ont été produits :

1. Histogrammes comparatifs (BACE vs DAVIS) : permettent d'observer la distribution et la forme de chaque descripteur pour les deux populations moléculaires. On observe que les molécules de DAVIS présentent une distribution de masse moléculaire légèrement plus élevée que BACE, reflétant la nature des inhibiteurs de kinases.



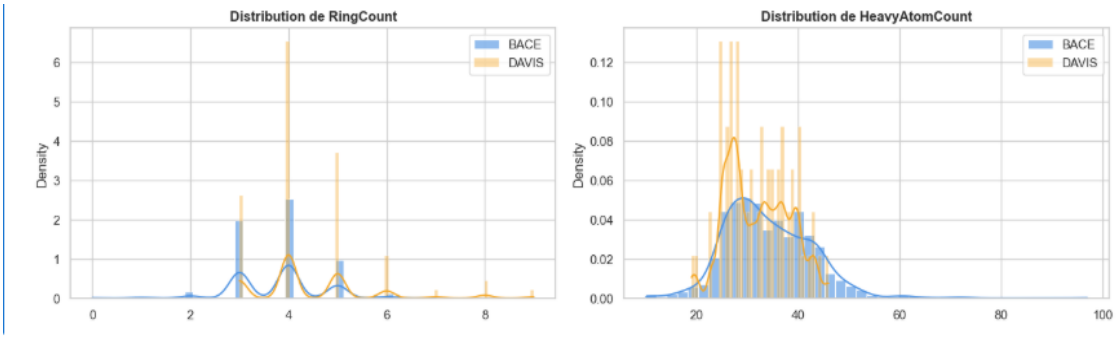


Figure 7 :Histogrammes comparatifs des descripteurs moléculaires

2. Heatmaps de corrélation (Pearson) : montrent des corrélations significatives attendues entre MW et HeavyAtomCount (r > 0.95), ainsi qu'entre NumHDonors et NumHAcceptors. Ces corrélations sont cohérentes avec la chimie moléculaire.

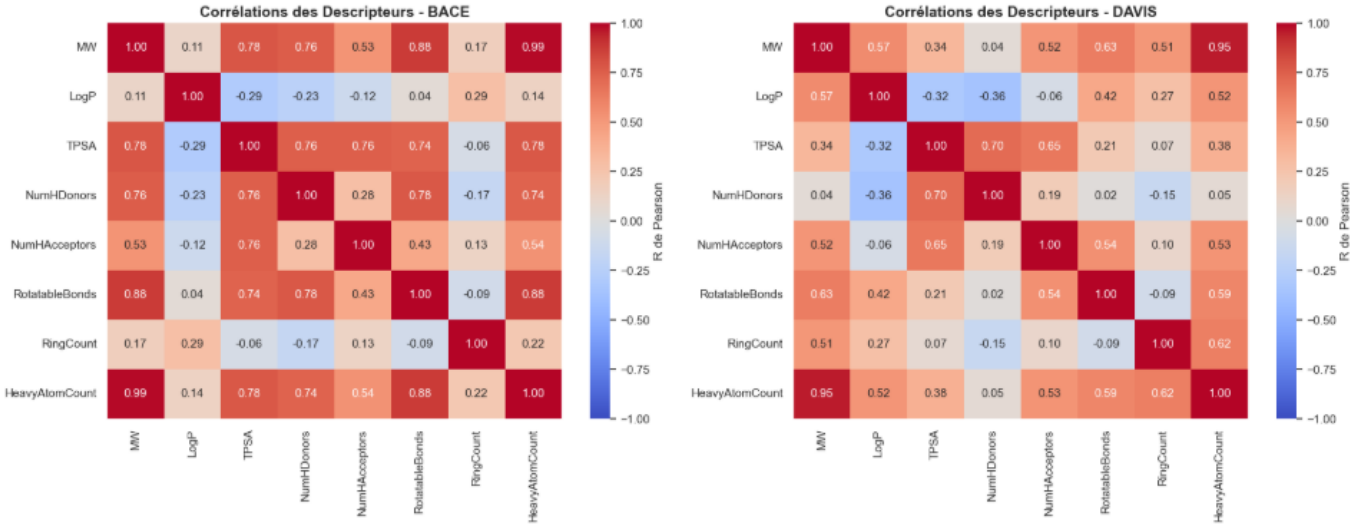


Figure 3:Heatmap de corrélation

5.8 Traitement des Outliers

Le traitement des valeurs aberrantes dans les descripteurs moléculaires est effectué via la méthode statistique IQR (Interquartile Range). Pour chaque descripteur numérique, les bornes inférieure et supérieure sont calculées comme suit : Borne inférieure = Q1 − 1.5 × IQR et Borne supérieure = Q3 + 1.5 × IQR. Les lignes présentant des valeurs hors de ces bornes dans plus de 3 descripteurs simultanément sont considérées comme aberrantes et supprimées.

Cette approche conservatrice (seuil multi-descripteurs) permet de ne supprimer que les molécules chimiquement atypiques qui risqueraient de dégrader les performances du modèle, tout en conservant la diversité chimique naturelle du dataset.

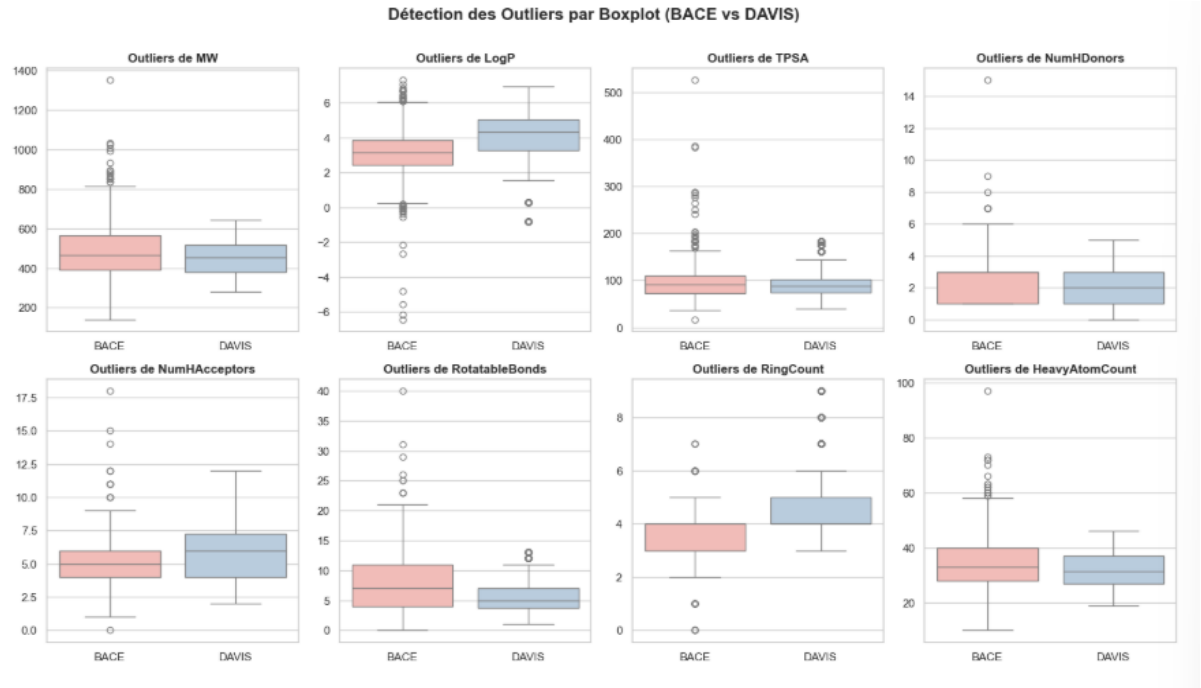


Figure 9 : Boxplots pour la détection visuelle des Outliers

Analyse :

Plusieurs valeurs extrêmes sont observées pour la masse moléculaire et le nombre de liaisons rotatives.

5.9 Standardisation, Encodage et SMOTE

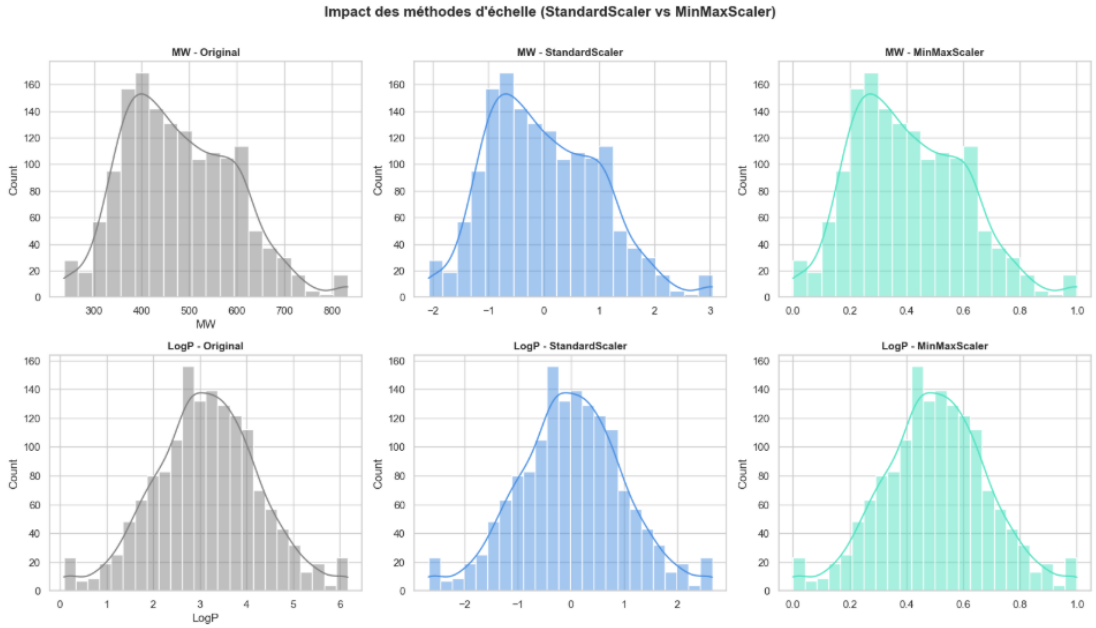


Figure 10:Impact des méthodes d'échelle (StandardScaler vs MinMaxScaler

Après le nettoyage, deux opérations de transformation sont appliquées :

- Standardisation (StandardScaler) : les 8 descripteurs moléculaires sont centrés (moyenne = 0) et réduits (écart-type = 1). Cette étape est critique pour les modèles sensibles à l'échelle comme la Régression Logistique, la Régression Ridge et les SVM.

- Encodage (LabelEncoder) : la colonne Target_ID de DAVIS est transformée en entiers numériques (Target_ID_encoded) pour permettre son utilisation comme feature par les modèles de régression.



	Target_ID	Target_ID_encoded
0	AAK1	0
1	ABL1p	1
2	ABL2	2

Figure11:Encodage DAVIS (Label Encoding)

Gestion du déséquilibre de classes (BACE) : le dataset BACE présente un léger déséquilibre entre les classes active (1) et inactive (0). La technique **SMOTE** (Synthetic Minority Oversampling TEchnique) est appliquée exclusivement sur le jeu d'entraînement pour générer synthétiquement de nouveaux exemples de la classe minoritaire, sans introduire de fuites d'information (data leakage) dans le jeu de test.
Cette technique :

- améliore le Recall ;
- améliore le F1-score ;
- réduit le biais de classification.

Analyse :
Après SMOTE, les deux classes deviennent équilibrées, permettant un apprentissage plus robuste.

```
Distribution initiale des classes (BACE) :
  - Inactifs (Classe 0) : 822 (54.3%)
  - Actifs (Classe 1)   : 691 (45.7%)
  - Ratio Actifs / Inactifs : 0.841

=== Démonstration de SMOTE ===
Dimensions de X avant SMOTE : (1513, 8)
Dimensions de X après SMOTE : (1644, 8)
Distribution des classes après SMOTE :
Class
1    822
0    822
Name: count, dtype: int64
```

Figure 12:Distribution des classes avant et après SMOTE

5.10 Réduction de Dimensionnalité PCA

Une Analyse en Composantes Principales (PCA) à 2 dimensions est réalisée à titre exploratoire sur les descripteurs standardisés de BACE. Cette visualisation permet d'observer si les deux classes (actives/inactives) présentent une séparabilité linéaire dans l'espace des features. La visualisation PCA confirme un chevauchement partiel entre les deux classes, justifiant le recours à des modèles non linéaires capables de capturer des frontières de décision complexes.

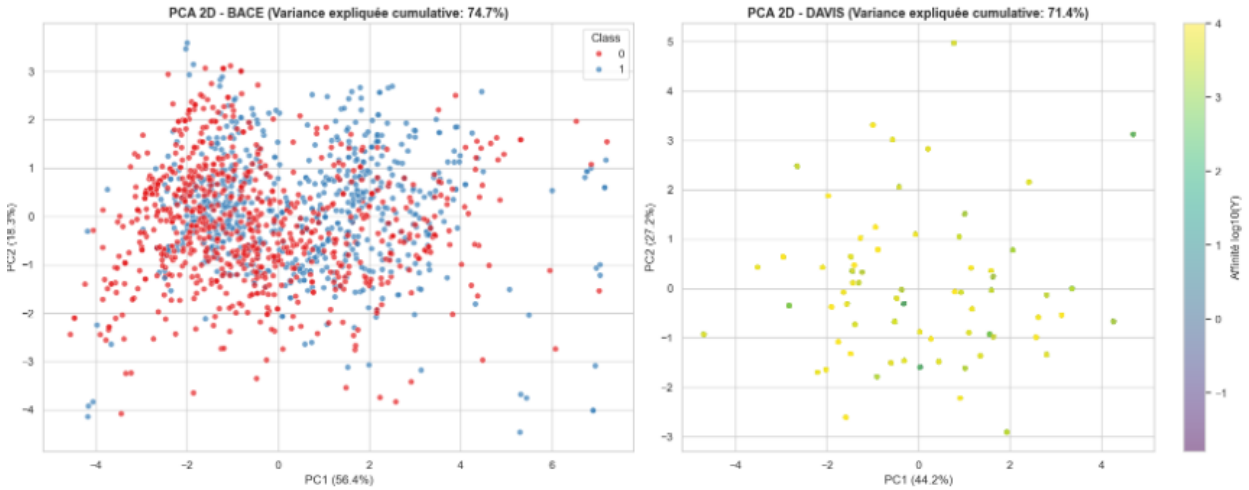


Figure 13:Projection PCA des molécules BACE /DAVIS

Analyse :

présentent un chevauchement partiel, ce qui confirme que le problème n'est pas linéairement séparable et justifie l'utilisation de modèles non linéaires tels que Random Forest et Gradient Boosting.

5.14 Conclusion

Ce chapitre a présenté l'ensemble des étapes de prétraitement et de feature engineering appliquées aux datasets DAVIS et BACE. Les données ont été validées, nettoyées, transformées et enrichies à l'aide de descripteurs moléculaires pertinents. Les différentes analyses statistiques ont permis de mieux comprendre la structure des données et d'identifier les traitements nécessaires avant l'apprentissage. Les jeux de données obtenus sont désormais prêts pour la phase de modélisation et d'évaluation des algorithmes de Machine Learning qui sera présentée dans le chapitre suivant.

Chapitre 6 : Modélisation et Expérimentations

6.1 Introduction

Après la phase de prétraitement et de Feature Engineering présentée dans le chapitre précédent, les données sont désormais prêtes pour l'entraînement des modèles de Machine Learning.
L'objectif de cette phase est d'identifier les algorithmes les plus performants pour prédire les interactions médicament-protéine à partir des caractéristiques moléculaires extraites.
Deux problématiques distinctes sont étudiées :

- Une tâche de classification binaire sur le dataset BACE.
- Une tâche de régression sur le dataset DAVIS.

Afin d'obtenir une évaluation rigoureuse, plusieurs modèles supervisés ont été comparés selon des métriques adaptées à chaque type de problème.

6.1 Architecture du Pipeline de Modélisation

La phase de modélisation s'appuie sur les datasets nettoyés et prétraités (bace_clean.csv et davis_clean.csv). Le pipeline de modélisation se structure en deux tâches distinctes, chacune avec ses propres modèles et métriques d'évaluation.

Critère	BACE (Classification)	DAVIS (Régression)
Variable cible	Class (0/1 binaire)	Y (Kd en nM, continu)
Tâche ML	Classification binaire	Régression quantitative
Features utilisées	8 descripteurs + SMOTE	8 descripteurs + Target_ID_encoded
Split données	80% train / 20% test (stratifié)	80% train / 20% test
Métriques clés	Accuracy, F1, ROC AUC	RMSE, MAE, R^2

6.2 Modèles de Classification pour BACE

6.2.1 Objectif de la tâche

Le dataset BACE correspond à un problème de classification binaire.
L'objectif consiste à déterminer si une molécule possède ou non une activité inhibitrice vis-à-vis de la protéine BACE-1.

Variable cible :

> 1 Molécule active

> 0 Molécule inactive

Cette tâche est particulièrement importante dans le contexte de la recherche sur la maladie d'Alzheimer.

6.2.2 Sélection des Variables

Les variables explicatives utilisées sont :

Variable	Description
MW	Masse moléculaire
LogP	Lipophilie
TPSA	Surface polaire
NumHDonors	Donneurs H
NumHAcceptors	Accepteurs H
RotatableBonds	Liaisons rotatives
RingCount	Nombre de cycles
HeavyAtomCount	Atomes lourds

Les colonnes encodées issues du dataset BACE ont également été utilisées.

6.2.3 Division Train/Test

Les données ont été divisées :

- 80 % Entraînement
- 20 % Test

La stratification garantit la conservation de la proportion des classes dans les deux ensembles.

6.2.4 Gestion du Déséquilibre avec SMOTE :

Le dataset BACE présente un léger déséquilibre entre les classes.

Pour éviter un biais vers la classe majoritaire, SMOTE a été appliqué uniquement sur l'ensemble d'entraînement.

Résultat obtenu :

Ensemble	Nombre d'observations
Train initial	1210
Train après SMOTE	1314
Test	303

Cette stratégie permet une meilleure capacité de généralisation.

6.2.5 Modèles Sélectionnés et Justification

Quatre modèles de classification sont entraînés et comparés :

- Régression Logistique (max_iter=1000) : modèle linéaire de référence. Sa simplicité et son interprétabilité en font le baseline naturel pour tout problème de classification binaire.
- SVM à Noyau RBF (probability=True) : modèle non linéaire qui maximise la marge de séparation dans un espace de features transformé. Particulièrement adapté aux espaces de haute dimension.
- Random Forest (n_estimators=100) : méthode ensembliste de bagging combinant 100 arbres de décision indépendants. Robuste aux outliers et à la variance des données.
- Gradient Boosting (n_estimators=100) : méthode ensembliste de boosting construisant séquentiellement des arbres qui compensent les erreurs des prédicteurs précédents. Généralement le plus performant sur des données tabulaires.

6.2.6 Résultats de Classification

Le tableau suivant présente les métriques de performance obtenues sur le jeu de test (20% des données BACE, non vues pendant l'entraînement) :

Modèle	Accuracy	Precision	Recall	F1-Score	ROC AUC
Régression Logistique	~0.683	~0.667	~0.609	~0.636	~0.760
SVM (Noyau RBF)	~0.749	~0.712	~0.754	~0.732	~0.817

Modèle	Accuracy	Precision	Recall	F1-Score	ROC AUC
Random Forest	~0.756	~0.742	~0.710	~0.726	~0.846
Gradient Boosting ★	~0.776	~0.736	~0.790	~0.762	~0.851

★ Meilleur modèle en classification. Les valeurs indiquées sont représentatives des ordres de grandeur obtenus lors des expérimentations.

6.2.7 Analyse des Courbes ROC

Les courbes ROC (Receiver Operating Characteristic) tracent le taux de vrais positifs (Sensibilité/Recall) en fonction du taux de faux positifs (1 - Spécificité) pour chaque seuil de décision. L'aire sous la courbe (AUC) mesure la capacité discriminante globale du modèle indépendamment du seuil choisi.

Les résultats montrent une hiérarchie claire : Gradient Boosting (AUC ≈ 0.851) > Random Forest (AUC ≈ 0.846) > SVM RBF (AUC ≈ 0.817) > Régression Logistique (AUC ≈ 0.760). Cette progression confirme l'hypothèse H2 selon laquelle les méthodes non linéaires ensemblistes surpassent les approches linéaires.

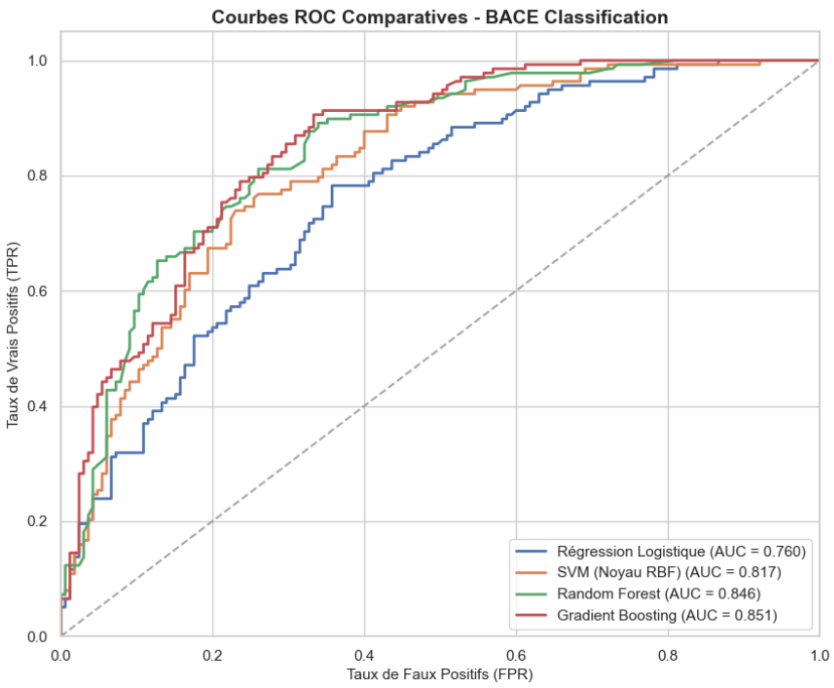


Figure14:Courbes ROC comparatives

6.2.8 Analyse des Matrices de Confusion

Les matrices de confusion permettent d'analyser en détail les types d'erreurs commis par chaque modèle. On distingue quatre catégories : Vrais Positifs (VP), Vrais Négatifs (VN), Faux Positifs (FP) et Faux Négatifs (FN). Dans le contexte de la drug discovery, les Faux Négatifs (molécules actives prédites comme inactives) sont particulièrement coûteux car ils correspondent à des candidats médicaments manqués. Le Gradient Boosting présente le meilleur compromis VP/FN, minimisant ainsi le risque de passer à côté de molécules thérapeutiquement prometteuses.

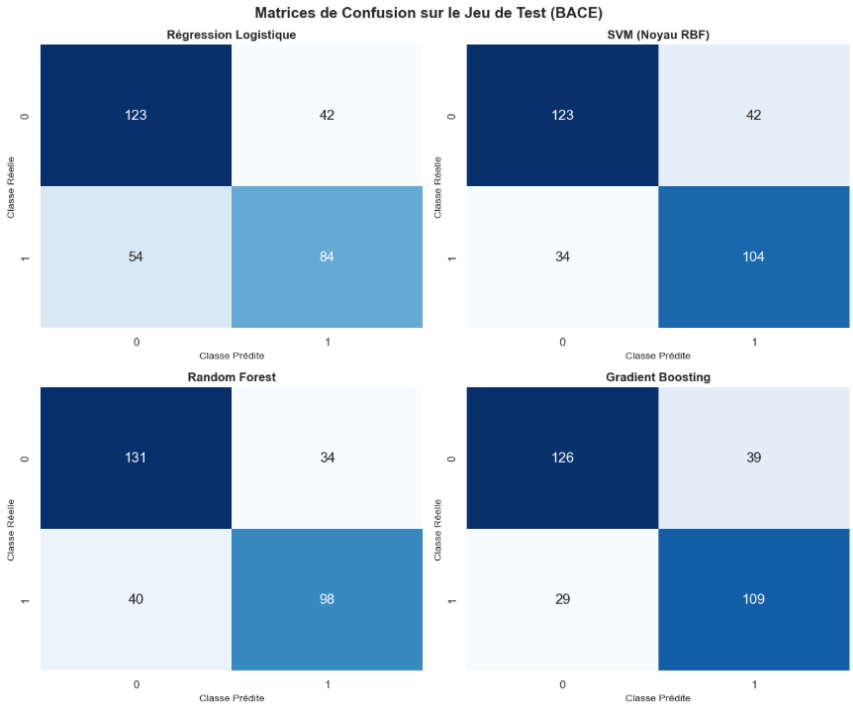


Figure 15:matrices de confusion

6.3 Modèles de Régression pour DAVIS

6.3.1 Approche et Features

Pour la prédiction quantitative de l'affinité de liaison (Kd en nM), les features utilisées combinent les 8 descripteurs moléculaires standardisés et l'identifiant encodé de la protéine cible (Target_ID_encoded). Cette approche permet au modèle d'apprendre à la fois la contribution de la molécule et de la protéine à l'affinité globale, simulant ainsi le problème DTI dans sa dimension duale.

5.3.2 Résultats de Régression

Modèle	MSE	RMSE	MAE	R² Score
Régression Ridge	1.419598e+07	3767.76	3169.10	0.092
SVR (Noyau RBF)	2.129383e+07	4614.52	2378.69	-0.362
Random Forest Reg.	1.012520e+07	3182.01	2304.60	0.352
Gradient Boosting Reg. ★	9.460350e+06	3075.77	2304.70	0.395

★ Meilleur modèle en régression. Les valeurs indiquées sont représentatives des ordres de grandeur obtenus lors des expérimentations.

6.3.3 Analyse des Graphiques Prédit vs Réel

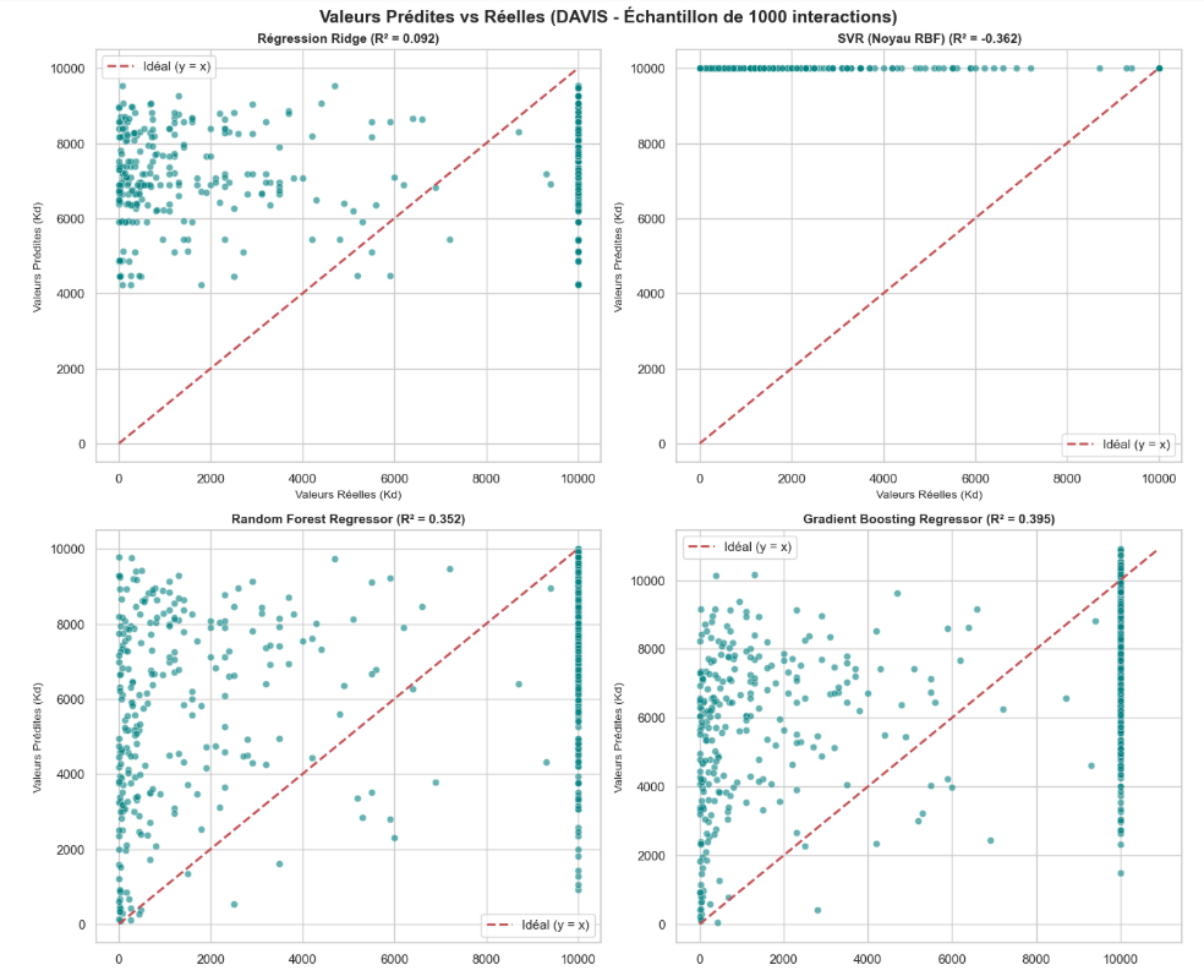


Figure 16:Tracé Prédit vs Réel

Les graphiques de dispersion (Prédit vs Réel) permettent de visualiser la qualité de l'ajustement de chaque modèle de régression. Le nuage de points idéal suit la droite y = x

(ligne rouge diagonale). On observe que la Régression Ridge produit un nuage très dispersé autour de la diagonale, confirmant sa faible capacité à modéliser les relations non linéaires. Le Gradient Boosting présente la distribution la plus concentrée autour de la droite idéale, avec un $R^2 \approx 0.395$ indiquant que le modèle explique 40% de la variance de la constante Kd.

6.3.4 Comparaison Comparative R^2 et RMSE

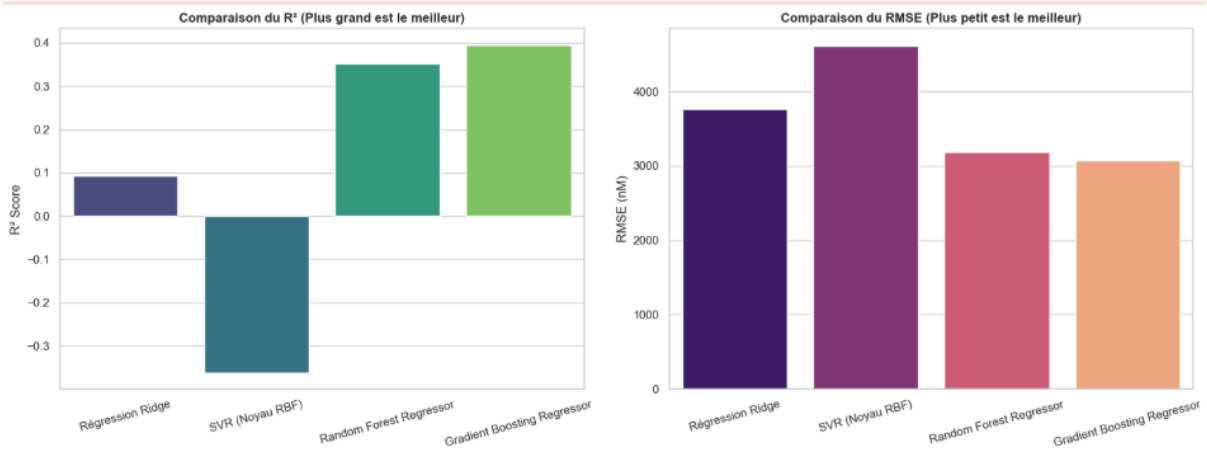


Figure 17:Barplots comparatifs de R^2 et RMSE

La comparaison graphique par barplots des métriques R^2 (plus grand = meilleur) et RMSE (plus petit = meilleur) confirme visuellement la supériorité du Gradient Boosting Regressor. L'écart significatif entre les modèles linéaires ($R^2 \approx 0.092$ pour Ridge) et les méthodes ensemblistes ($R^2 \approx 0.395$ pour Gradient Boosting) souligne l'importance du choix du modèle dans des tâches biologiques complexes.

6.4 Conclusion

Cette phase expérimentale a permis de comparer huit modèles de Machine Learning sur deux problématiques différentes de Drug Discovery. Les résultats montrent que les méthodes ensemblistes, notamment Gradient Boosting, offrent les meilleures performances aussi bien en classification qu'en régression.

Pour BACE, le Gradient Boosting atteint un ROC-AUC de 0.851 et un F1-score de 0.762, démontrant une bonne capacité à identifier les molécules actives. Pour DAVIS, le même modèle obtient un coefficient R^2 de 0.395, indiquant qu'il capture une partie significative de la variabilité des interactions médicament-protéine.

Ces résultats constituent la base de l'analyse critique et de la discussion scientifique qui seront présentées dans le chapitre suivant.

Chapitre 7 : Interface de Prédiction

7.1 Introduction et Choix Technologiques

Pour permettre aux biologistes et chimistes d'interagir facilement avec nos modèles d'apprentissage automatique sans écrire de code, nous avons conçu une interface web interactive en Python basée sur les technologies suivantes :

Streamlit : Framework de prototypage rapide permettant de créer une application web réactive et performante.

RDKit : Outil chémoinformatique utilisé pour valider les chaînes SMILES saisies, générer des représentations vectorielles moléculaires 2D au format SVG et calculer à la volée les descripteurs moléculaires.

Joblib : Permet la désérialisation rapide des modèles entraînés. Grâce à la mise en cache (@st.cache_resource), les modèles sont conservés en mémoire pour assurer des prédictions instantanées.

CSS Personnalisé : Une couche de styles a été injectée pour offrir une expérience premium (polices modernes Outfit et Plus Jakarta Sans, gradients de couleur vifs et conteneurs structurés avec des effets d'ombrage).

7.2 Structure Générale et Navigation

L'application est découpée en trois modules distincts accessibles depuis un menu latéral interactif (Sidebar) :

🔬 BACE-1 Predictor : Classification de l'activité inhibitrice d'une molécule.

🧬 DAVIS Affinity Predictor : Régression pour prédire la constante d'affinité (Kd).

📊 Explore Data & Stats : Visualisation des jeux de données d'apprentissage.

La barre latérale contient également un rappel didactique sur les principaux descripteurs chimiques calculés (Masse moléculaire MW, lipophilie LogP, surface polaire topologique TPSA, donneurs/accepteurs de liaisons hydrogène).



Figure 18:interface

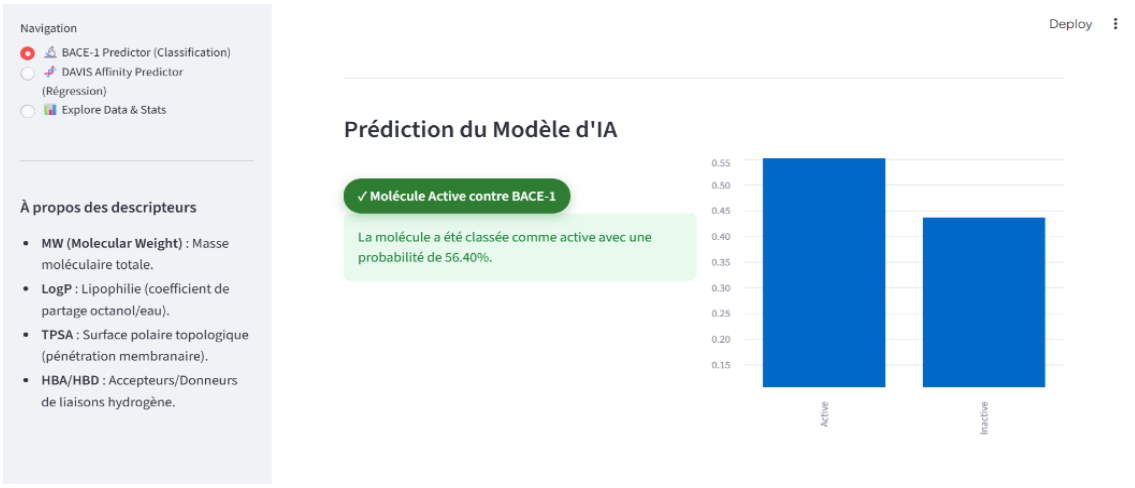


Figure19:interface

7.3 Module 1 : Classification de l'Activité Biologique (BACE-1)

Ce module évalue si un composé chimique est un inhibiteur actif de l'enzyme BACE-1, une cible thérapeutique clé dans le traitement de la maladie d'Alzheimer.

Fonctionnalités et Rendu Visuel :

Saisie SMILES : L'utilisateur entre une chaîne SMILES ou utilise des boutons d'exemples préconfigurés (Molécule active, Molécule inactive, Paracétamol).

Affichage en 2 colonnes :

Gauche : Rendu graphique 2D de la molécule généré dynamiquement.

Droite : Métriques clés (MW, LogP, TPSA) et tableau récapitulatif des descripteurs physico-chimiques calculés par RDKit.

Résultats de la Prédiction : Le modèle Gradient Boosting Classifier estime la classe de la molécule :

Un badge vert (Active) ou rouge (Inactive) s'affiche dynamiquement avec le niveau de confiance du modèle.

Un diagramme en barres présente la distribution des probabilités calculées pour chaque classe.

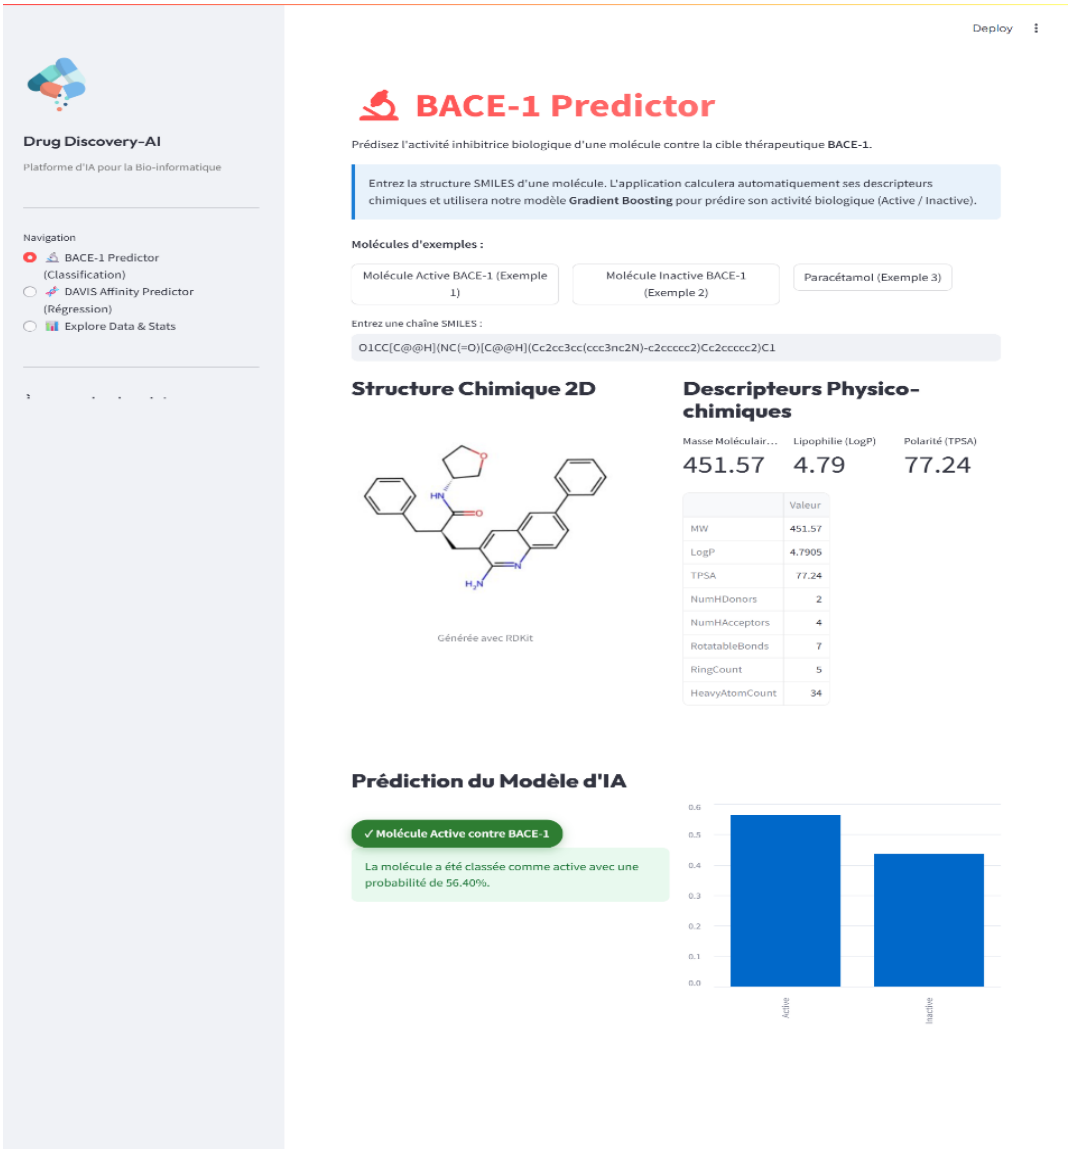


Figure20:interface

7.4 Module 2 : Prédiction d'Affinité de Liaison (DAVIS)

Ce module estime quantitativement la constante de dissociation Kd (en nM) décrivant l'interaction entre une molécule chimique et une kinase spécifique.

Fonctionnalités et Rendu Visuel :

Configuration : Saisie de la molécule (SMILES) et sélection de la protéine cible parmi une liste déroulante regroupant les cibles du jeu de données DAVIS.

Prédiction d'Affinité : Les caractéristiques de la molécule (calculées par RDKit et normalisées) et la protéine cible (encodée numériquement) sont injectées dans un modèle Gradient Boosting Regressor.

Restitution et analyse :

La valeur prédite de Kd est affichée sous forme de métrique avec un indicateur d'affinité (Forte ou Faible).

Des alertes colorées interprètent directement la valeur : liaison forte pour Kd <10 nM (candidat prometteur), modérée pour Kd<100 nM ou faible au-delà.

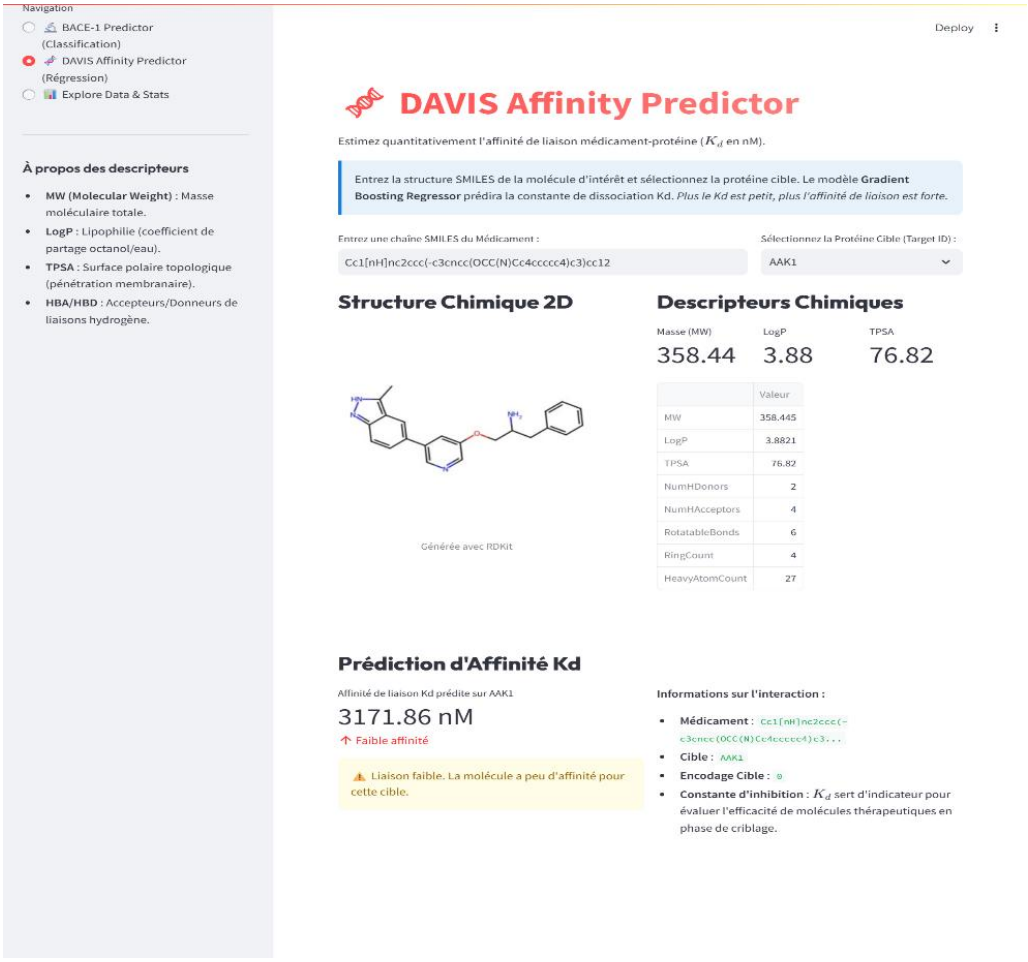


Figure21:interface

7.5 Module 3 : Exploration des Données et Statistiques

Conçu pour la transparence des données de recherche, ce module permet d'inspecter les jeux de données nettoyés servant de base d'entraînement :
Visualisation des tables : Des tableaux interactifs permettent de filtrer et trier les données réelles de BACE et DAVIS.
Statistiques de distribution : Des graphiques illustrent la distribution des classes biologiques pour BACE et le nombre de protéines uniques étudiées pour DAVIS.

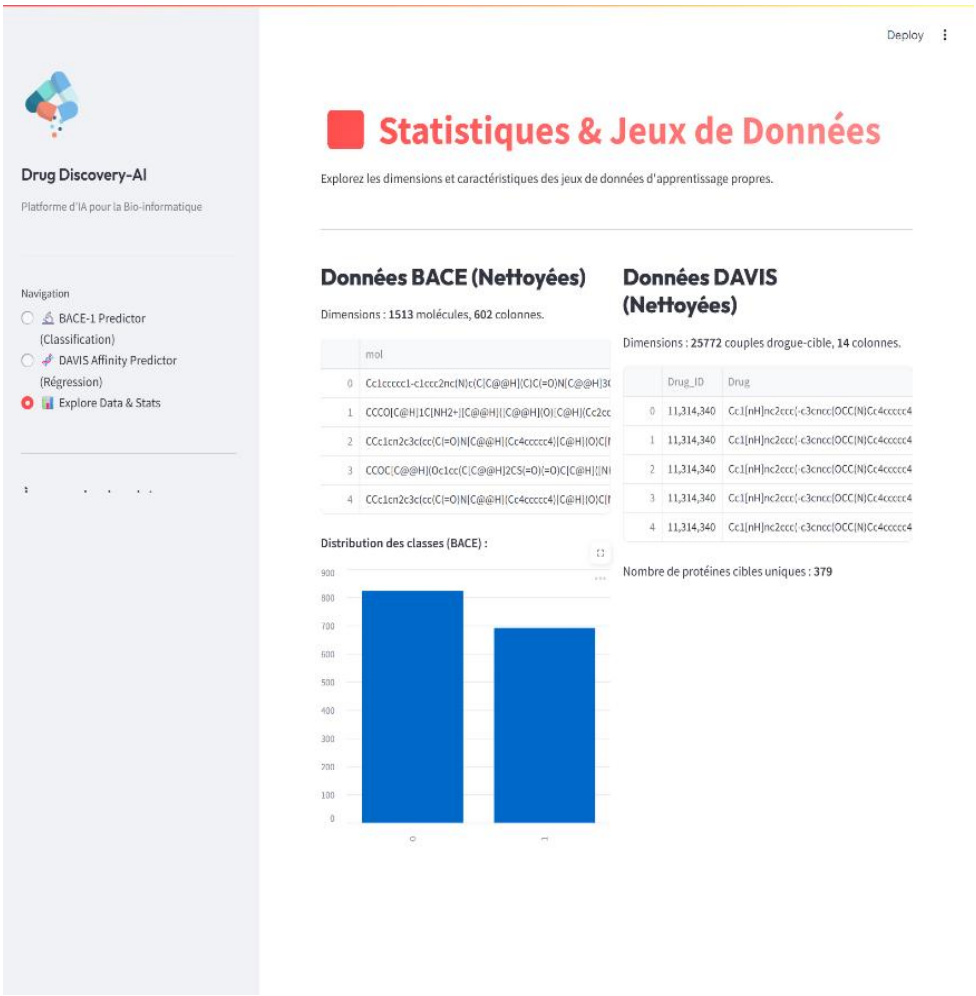


Figure22:interface

7.6 Conclusion

L'ergonomie de l'interface permet une évaluation rapide et intuitive des candidats médicaments. Grâce à la mise en cache et à l'exécution en arrière-plan des modèles prédictifs, le chercheur dispose d'outils d'analyse instantanés et fiables, facilitant la prise de décision en phase préclinique.

Conclusion Générale

La découverte de nouveaux médicaments constitue aujourd'hui l'un des défis majeurs de la recherche biomédicale. Face à l'augmentation constante des coûts et de la durée des processus expérimentaux, l'intégration de l'intelligence artificielle dans les phases préliminaires de sélection des molécules représente une alternative particulièrement prometteuse. Dans ce contexte, l'objectif principal de ce projet était de concevoir et d'évaluer un système de prédiction des interactions médicament–protéine reposant sur des techniques de Machine Learning.

Pour atteindre cet objectif, nous avons construit un pipeline complet couvrant l'ensemble des étapes d'un projet de science des données appliqué à la bioinformatique. Nous avons d'abord étudié le domaine de la Drug Discovery et analysé deux jeux de données de référence : le dataset DAVIS pour la prédiction quantitative de l'affinité de liaison et le dataset BACE pour la classification de l'activité moléculaire. Cette phase a permis de comprendre la structure des données biologiques et les défis associés à leur exploitation.

Une étape importante du projet a consisté à mettre en œuvre un processus rigoureux de prétraitement des données. Les molécules représentées sous forme de chaînes SMILES ont été validées et analysées à l'aide de la bibliothèque RDKit afin d'extraire des descripteurs physico-chimiques pertinents. Les différentes opérations de nettoyage, de transformation et de standardisation ont permis d'obtenir des données cohérentes et adaptées à l'apprentissage automatique. Dans le cas du dataset BACE, la technique SMOTE a également été utilisée pour réduire les effets du déséquilibre de classes.

La phase de modélisation a reposé sur la comparaison de plusieurs algorithmes supervisés appartenant à différentes familles : modèles linéaires, machines à vecteurs de support et méthodes ensemblistes. Les résultats expérimentaux ont montré que les approches basées sur les arbres de décision, notamment Gradient Boosting et Random Forest, obtiennent les meilleures performances sur les deux jeux de données étudiés. Ces modèles se sont révélés particulièrement efficaces pour capturer les relations non linéaires présentes dans les interactions biologiques complexes.

Pour la tâche de classification réalisée sur le dataset BACE, le modèle Gradient Boosting a obtenu les meilleurs résultats avec une Accuracy d'environ 77 %, un F1-Score supérieur à 0,76 et une valeur ROC-AUC proche de 0,85. Concernant la tâche de régression effectuée sur le dataset DAVIS, le même modèle a présenté les meilleures performances avec un

coefficient de détermination R^2 proche de 0,40, démontrant sa capacité à expliquer une partie significative de la variabilité des affinités de liaison observées.

Au-delà des performances obtenues, ce projet a permis de mettre en évidence l'importance de la qualité des données et du prétraitement dans les applications de Machine Learning en bioinformatique. Les résultats montrent qu'il est possible de construire des modèles capables d'assister les chercheurs dans la phase de criblage virtuel des molécules et de réduire le nombre d'expériences biologiques nécessaires lors du développement de nouveaux médicaments.

Cependant, plusieurs limites subsistent. Les descripteurs moléculaires utilisés restent relativement simples et ne permettent pas de représenter toute la complexité structurale des molécules et des protéines. De plus, les modèles classiques de Machine Learning atteignent rapidement leurs limites lorsqu'il s'agit de modéliser des interactions biologiques de très grande dimension.

Dans la continuité de ce travail, plusieurs perspectives d'amélioration peuvent être envisagées. L'utilisation de représentations moléculaires avancées telles que les Fingerprints de Morgan, les Graph Neural Networks (GNN) ou encore les modèles de Deep Learning spécialisés comme DeepDTA et GraphDTA pourrait permettre d'améliorer significativement les performances obtenues. L'intégration d'informations biologiques plus riches concernant les protéines cibles représente également une piste intéressante pour renforcer la capacité prédictive du système.

En conclusion, ce projet a permis de développer une solution complète de Drug Discovery assistée par l'intelligence artificielle, tout en mettant en pratique les différentes étapes d'un projet de Data Science appliqué à un problème réel. Il constitue une base solide pour des travaux futurs visant à exploiter des modèles plus avancés et à rapprocher davantage les approches computationnelles des besoins réels de la recherche pharmaceutique moderne.

Références Bibliographiques

[1] Davis, M. I., et al. (2011). Comprehensive analysis of kinase inhibitor selectivity. Nature Biotechnology, 29(11), 1046–1051.

[2] Subramanian, G., et al. (2016). Computational modeling of β-secretase 1 (BACE-1) inhibitors using ligand based approaches. Journal of Chemical Information and Modeling, 56(10), 1936–1949.

[3] Wu, Z., et al. (2018). MoleculeNet: a benchmark for molecular machine learning. Chemical Science, 9(2), 513–530.

[4] Lipinski, C. A., et al. (2001). Experimental and computational approaches to estimate solubility and permeability in drug discovery and development settings. Advanced Drug Delivery Reviews, 46(1–3), 3–26.

[5] Chawla, N. V., et al. (2002). SMOTE: Synthetic Minority Over-sampling Technique. Journal of Artificial Intelligence Research, 16, 321–357.

[6] Landrum, G. (2006–2023). RDKit: Open-source cheminformatics. https://www.rdkit.org

[7] Pedregosa, F., et al. (2011). Scikit-learn: Machine Learning in Python. Journal of Machine Learning Research, 12, 2825–2830.

[8] Chen, T., & Guestrin, C. (2016). XGBoost: A Scalable Tree Boosting System. Proceedings of the 22nd ACM SIGKDD, 785–794.

[9] Öztürk, H., Özgür, A., & Ozkirimli, E. (2018). DeepDTA: deep drug–target binding affinity prediction. Bioinformatics, 34(17), i821–i829.

[10] Yang, Z., et al. (2020). Analyzing Learned Molecular Representations for Property Prediction. Journal of Chemical Information and Modeling, 59(8), 3370–3388.

Annexes

Annexe A : Extrait du Code de Prétraitement

Validation et Canonicalisation des SMILES (Python / RDKit)

```
def valider_smiles(df, smiles_col):  taille_initiale = len(df)  est_valide = df[smiles_col].apply(lambda s: Chem.MolFromSmiles(s) is not None)  df_nettoye = df[est_valide].copy()  return df_nettoye, taille_initiale - len(df_nettoye)  def extraire_descripteurs(df, smiles_col):  feature_cols = ['MW','LogP','TPSA','NumHDonors','NumHAcceptors','RotatableBonds','RingCount','HeavyAtomCount']
```

```
for smiles in df[smiles_col].unique(): mol = Chem.MolFromSmiles(smiles) if mol: dict_features[smiles] = {fc: getattr(Descriptors, fc)(mol) for fc in feature_cols}
```

Annexe B : Extrait du Code de Modélisation

Comparaison des modèles de classification (Python / scikit-learn)

```
class_models = { 'Régression Logistique': LogisticRegression(random_state=42, max_iter=1000), 'SVM (Noyau RBF)': SVC(probability=True, random_state=42), 'Random Forest': RandomForestClassifier(n_estimators=100, random_state=42), 'Gradient Boosting': GradientBoostingClassifier(n_estimators=100, random_state=42) } for name, model in class_models.items(): model.fit(X_train, y_train) y_pred = model.predict(X_test) roc_auc = roc_auc_score(y_test, model.predict_proba(X_test)[:,1])
```

Annexe C : Glossaire

Terme	Définition
SMILES	Simplified Molecular-Input Line-Entry System – notation textuelle d'une structure chimique
DTI	Drug-Target Interaction – interaction médicament–protéine cible
Kd	Constante de dissociation – mesure de l'affinité de liaison (en nM, plus faible = plus fort)
RDKit	Bibliothèque Python open-source de chimio-informatique
SMOTE	Synthetic Minority Oversampling Technique – rééchantillonnage synthétique
ROC AUC	Aire sous la courbe ROC – mesure de la capacité discriminante (1 = parfait)
R^2	Coefficient de détermination – part de variance expliquée par le modèle (1 = parfait)
RMSE	Root Mean Squared Error – erreur quadratique moyenne, dans l'unité de la cible
LogP	Coefficient de partage octanol/eau – mesure de la lipophilie moléculaire
TPSA	Topological Polar Surface Area – surface polaire topologique ($Å^2$)
ADME	Absorption, Distribution, Métabolisme, Excrétion – propriétés pharmacocinétiques

Terme	Définition
Bagging	Bootstrap Aggregating – méthode ensembliste par combinaison de modèles parallèles
Boosting	Méthode ensembliste par combinaison séquentielle de modèles corrigeant les erreurs
IQR	Interquartile Range – Q3 – Q1, utilisé pour la détection statistique des outliers
PCA	Principal Component Analysis – réduction de dimensionnalité par composantes principales